

# Estadística descriptiva: Introducción

Comenzamos los vídeos  
de la asignatura de Estadística

con este dedicado  
a la estadística descriptiva.

Este vídeo es un complemento

del material  
que encontraréis en vuestra aula:

las notas de estudio  
y los resúmenes conceptuales.

El vídeo contiene explicaciones  
de los conceptos básicos,

animaciones ilustrativas  
y ejemplos resueltos.

Os recomendamos  
que visualicéis los vídeos

con el material a la vista  
para poder tomar notas

y poder continuar  
y mejorar vuestro estudio personal.

Comenzamos pues  
con la estadística descriptiva.

En esta primera sesión,

introduciremos los conceptos básicos

de la estadística descriptiva.

Comenzaremos por la población,

que es el conjunto de individuos  
que queremos estudiar.

Normalmente, no tenemos acceso  
a toda la población,

por lo cual  
se selecciona una muestra,

que es un subconjunto  
cualquiera de la población.

Y, sobre esta muestra accesible,  
estudiaremos una variable,

que es una característica  
objeto de nuestro estudio.

Gráficamente, la población  
serían todos los individuos.

Como a menudo  
no podemos acceder a todos ellos,

seleccionamos una muestra,

escogemos unos cuantos individuos  
de la población

y, a partir de esta muestra,

estudiamos  
los valores de alguna variable.

Vamos a estudiar  
unos ejemplos muy sencillos.

Imaginemos que la población

sea el conjunto  
de todos los estudiantes de la UOC.

Es muy difícil acceder a todos ellos.  
Escogeremos una muestra.

Podría ser los estudiantes  
que asisten a un determinado examen.

Y, a estos estudiantes,  
les medimos su altura.

Esto sería la variable.

Sobre la misma población,  
podríamos escoger otra muestra,

por ejemplo, los que usaron  
la biblioteca el mes anterior.

Y de ellos, se mira  
el número de libros que consultaron.

Una muestra un poco diferente

sería si queremos estudiar  
los yogures de cierta marca.

Esta muestra que proponemos  
es aleatoria, las otras no lo eran.

¿Por qué?  
Vamos a cada supermercado del barrio

y compramos, al azar,  
un yogur de esta marca.

Tendríamos una muestra aleatoria.

Y podemos estudiar, como variable,  
su fecha de caducidad.

Aquí tenemos, pues, tres ejemplos  
de población, muestra y variable.

Y una vez tenemos las variables,  
¿qué haremos?

Primero haremos  
un análisis univariante:

estudiaremos  
una variable por separado.

Lo que haremos será calcular  
los resúmenes numéricos

que nos ayuden a entender  
el centro de los valores

y cómo se distribuyen  
alrededor de ese centro.

Deberemos hacer también  
una buena representación gráfica

con el objetivo de llegar  
a conclusiones sobre los datos,

pero apoyadas en los resúmenes  
numéricos y en los gráficos,

no generales o de opinión,

sino apoyadas  
en un contenido numérico.

También nos servirá  
para comparar datos

referidos a la misma característica

sobre dos conjuntos diferentes  
de individuos,

o sea, compararemos dos poblaciones.  
Y, si trabajamos sobre una muestra,

veremos qué nos podemos preguntar

respecto a las características  
globales de la población.

Esto es la inferencia:

a partir de los resultados  
que obtengo de una muestra,

qué puedo saber  
sobre la población entera.

Hablando de tipos de variables,

distinguiremos  
entre variables categóricas,

que representan categorías  
o características de los individuos,

por ejemplo, el color de los ojos  
de los estudiantes de la UOC,

y variables cuantitativas,

que son las que vienen expresadas  
numéricamente.

Estas pueden ser discretas

cuando solo toman  
un número finito de valores

y, generalmente, provienen  
de contar unidades de cierta clase,

por ejemplo, el número de ordenadores  
en cada hogar de Catalunya,

que es un número entero  
y suele ser pequeño.

Esto sería una variable  
cuantitativa discreta.

Las variables cuantitativas continuas  
son las que pueden tomar

cualquier valor  
dentro de un intervalo.

Acostumbran a ser el resultado  
de medir algún fenómeno,

por ejemplo, las alturas  
de los edificios de una ciudad.

Suelen provenir, como he dicho,  
de medir alguna cantidad.

A veces, las categorías  
de una variable categórica

se identifican con números

y, en este caso,  
diremos que está codificada.

Por ejemplo, el tipo de ordenador

se podría codificar  
según este criterio:

1: PC, 2: PC portátil,  
3: MAC, 4: MAC portátil, 5: Otros.

Aquí, los números se usan  
como etiquetas de las categorías,

no es, de hecho,  
una variable numérica,

no es una variable cuantitativa,  
es una variable categórica.

Vamos a estudiar ahora

variables cualitativas  
y cuantitativas discretas.

Comenzamos con los números  
que vamos a calcular

y ahora explicaré  
qué representa cada uno de ellos.

Para estudiar un variable categórica

o una cuantitativa discreta  
que toma  $k$  valores diferentes,

donde  $k$  es un número pequeño, o sea,  
tendremos unas cuantas opciones,

$k$  opciones, empezaremos por averiguar  
el número total de individuos

de los que disponemos de información.

Esto será  $N$ ,  
el tamaño o medida de la población.

Y para cada uno  
de estos valores de la variable,

podemos calcular  $n$  sub  $i$ ,  
que es su frecuencia absoluta,

es decir, cuántos individuos  
hay en los que la variable

toma el valor  $x$  sub  $i$ .  
Esto lo denotaremos con  $n$  sub  $i$ .

A partir de esto,  
se puede calcular, a veces,

la frecuencia absoluta acumulada,  
es decir, el número de individuos

para los que la variable  
toma este valor o anteriores.

La designaremos con  $N$  sub  $i$   
y solo tiene sentido

si las variables  
u observaciones se pueden ordenar.

$N$  sub  $i$  sería  $n$  sub 1 más  $n$  sub 2...  
hasta  $n$  sub  $i$  menos 1.

El siguiente indicador  
que podemos calcular

es la frecuencia relativa,  
es decir, la proporción de individuos

en los que la variable  
toma este valor.

La designaremos como  $f$  sub  $i$ ,  
se suele dar en porcentaje

y es la frecuencia de este valor  
dividido por el total,

por el tamaño de la población.  
Siempre es un porcentaje:

$n$  sub  $i$  dividido por  $N$ .

Y, como con la frecuencia  
absoluta acumulada,

podemos calcular  
la frecuencia relativa acumulada,

la proporción de individuos  
en los que la variable

toma este valor o anteriores.

Se calcula  
sumando las frecuencias relativas

de los valores anteriores.

Bien, con esto ya tendremos

los resúmenes habituales  
de este tipo de variables.

Vamos a ver un ejemplo.

Partimos de una muestra

del tipo de ordenador

que usan los estudiantes  
y tenemos la codificación de antes:

1: PC, 2: PC portátil, 3: MAC,  
4: MAC portátil y 5: Otros.

Y aquí tenemos como una sopa de datos

donde es muy difícil  
entender cuántos hay,

están un poco mezclados.

Lo primero que haremos  
será hacer recuentos.

Vamos a contar  
las frecuencias de cada categoría.

Esto lo vamos a hacer

en la siguiente pantalla.

Disponemos las etiquetas  
de una manera razonable

y, simplemente, tenemos que recontar.

Hay 7 PC, 5 portátiles,  
3 MAC, 1 portátil y 4 de otros.

Con esto tendríamos las frecuencias  
absolutas de cada categoría.

Y sumándolas obtendríamos  
el tamaño de la población.

Y la frecuencia relativa  
es muy fácil de calcular,

simplemente, se divide por el total.

Tendríamos, pues,  
un 35 por ciento de PC,

un 25 por ciento  
de PC portátiles, etc.

Evidentemente,  
la suma de las frecuencias relativas

suma el 100 por cien.

Vamos a ver los gráficos

que se pueden obtener  
a partir de estas variables.

El más habitual  
es el diagrama de barras,

que tiene una barra

para cada categoría  
o valor de la variable

y en el eje vertical

marcaremos la frecuencia  
relativa o absoluta.

Aquí hemos marcado  
la frecuencia absoluta.

Hay 7 PC, 5 PC portátiles, etc.

Aquí ya se ve muy bien  
dónde está la mayoría

y cuál es la distribución.

Y también podemos hacer  
un diagrama de sectores.

Aquí se reparte un círculo  
en diferentes sectores

de forma que las superficies  
sean proporcionales

a las frecuencias de las categorías.

Aquí trabajaremos  
más con frecuencias relativas.

El 35 por ciento son PC,  
el 25 son PC portátiles, etc.

Aquí ya vemos, también,

la distribución  
de estos tipos de ordenadores.

Bien, estudiaremos ahora  
las variables numéricas.

Si disponemos de un conjunto  
de datos numéricos,

también tenemos  
unos indicadores que calcular.

Primero el tamaño de la población,  
el número de individuos.

Lo normal es calcular

el máximo y el mínimo de los valores  
que toma la variable

para ver el rango  
o cuán distribuida está la variable,

que es la diferencia  
entre el valor máximo y el mínimo.

Si el número de observaciones  
es pequeño,

podemos hacer un diagrama de puntos,

en el que los individuos  
se representan por puntos

dibujados encima  
del valor que les corresponde,

o un diagrama de tallo y hojas.  
Este diagrama es más complicado.

Veremos un ejemplo.  
Lo que se suele hacer

es partir cada observación  
de la variable en dos partes.

La primera son todos los dígitos  
menos el de más a la derecha

y será el tallo.  
El dígito a la derecha será la hoja.

Luego situaremos los tallos  
uno debajo de otro

y ordenados de manera creciente

y situaremos, junto a cada tallo,

las hojas que le corresponden  
también en orden creciente.

Quedará una forma un poco de árbol.

Ahora veremos un ejemplo.

Por ejemplo, estudiamos  
los días de hospitalización

de un grupo de pacientes  
sometidos al mismo tratamiento:

15, 15, 3...  
Están los resultados desordenados,

pero si los vamos situando  
en la recta real,

fácilmente vemos la distribución.  
Aquí tendríamos el 3,

los dos 15...  
Los iríamos poniendo aquí

y, sobre todo el último, el 623,  
ya se ve que está muy alejado,

es un punto aislado o extremal.

Se ve una concentración al principio

y este elemento muy discordante.

Vamos a hacer ahora  
un diagrama de tallo y hojas.

Para esto, nos basaremos,  
como en las notas de estudio,

en el número de minutos  
que necesita un ajedrecista

para ganar a un programa de ordenador  
en 15 partidas.

Tenemos estos valores,  
que están un poco dispersos,

y vamos a crear  
un diagrama de tallo y hojas.

Para ello,  
nos fijamos en todos los valores

y, como he comentado, los partimos:

el último dígito será la hoja  
y el primero será el tallo.

Pondremos los tallos ordenados:

veintes, treintas,  
cuarentas, cincuentas...

Aquí aparecen: veintes, treintas,  
cuarentas, cincuentas y sesentas.

Estos serán los tallos, las decenas.

Y ahora colocaremos, a la derecha,  
en orden creciente

y repetidas  
lo que haga falta, las hojas.

Por ejemplo, del 22, aquí iría el 2,

del 25, aquí iría el 5...  
De alguna manera,

no repetimos las decenas  
y vamos poniendo las unidades.

Lo hemos hecho con el 22 y el 25  
y lo haremos con cada uno.

Tendríamos que traer aquí el 35, etc.

Y cuando lo hagamos con todos ellos,

tendríamos ya la forma  
de esta distribución.

Vemos una forma,

vemos la concentración  
en los cuarenta

y este 60 que está un poco alejado.

Este sería el diagrama.

Por lo tanto,  
aquí quedaría el resumen:

un diagrama de puntos

y uno de tallo y hojas ya acabado

y con la forma de esta distribución.

Aquí están los tallos, las decenas,  
y, en las hojas, las unidades.

Vamos a ver qué pasa  
si tenemos muchos valores diferentes.

Si tenemos muchos individuos  
o muchos valores diferentes,

por ejemplo, más de 100,

no podemos poner un punto  
para cada uno,

quedaría muy poco representativo.

Normalmente, construimos  
la distribución de frecuencias

agrupando los valores  
y se procede de esta forma:

agrupamos las observaciones  
en intervalos,

generalmente  
todos de la misma anchura,

denominados clases.

Los intervalos  
tienen que ser adyacentes,

no hay que dejar agujeros,  
y tienen que cubrir todo el rango,

desde el mínimo al máximo.

Calcularemos  
el punto medio de cada intervalo,

que es la marca de clase.

Y calcularemos la frecuencia absoluta de cada clase.

Antes era la frecuencia absoluta de cada valor

y ahora es la de cada clase.

Es calcular cuántas observaciones caen en ese intervalo

y su frecuencia relativa o proporción de observaciones

que caen en el intervalo.

Esta distribución de frecuencias

se puede representar mediante los histogramas,

que son los gráficos que acabaremos construyendo.

Vamos a ver un ejemplo.

Consideremos dos tipos de histogramas.

Si todas las clases tienen la misma anchura,

podemos construir el histograma

marcando como altura de cada rectángulo

la frecuencia relativa

y tendremos un histograma  
de frecuencias relativas,

como en este caso:  
la clase de 0 a 2, un 20 por ciento

y la clase de 2 a 4,  
el 80 por ciento.

Simplemente,  
marcamos en el eje x de 0 a 2

y de 2 a 4 y ponemos una barra

que tenga la altura  
en la frecuencia relativa.

Esto sería en este caso

donde las clases  
tienen la misma anchura,

la misma amplitud.

En otros casos,

conviene más  
un histograma de densidad

en el que, para cada clase,  
representaremos un rectángulo

que tiene como altura

la frecuencia relativa  
dividida por la anchura de la clase,

por la longitud de la clase.

¿Por qué hacemos esto?  
Imaginemos este caso:

la clase de 0 a 2  
tiene el 20 por ciento

y la clase de 2 a 6,  
el 80 por ciento,

pero la clase de 2 a 6  
es mucho más ancha, mucho más grande.

Si representásemos la clase de 2 a 6  
a una altura del 80 por ciento,

esta clase  
estaría sobrerrepresentada,

tendría una altura mucho más grande.

Se vería demasiada diferencia.

Lo que hacemos es dividir  
por la anchura del rectángulo.

El 20 por ciento  
dividido por 2 es 0,1

y el 80 por ciento  
dividido por 4 es 0,2.

Esta distribución  
es más representativa

y el total del área es 1.

Por lo tanto,  
estamos distribuyendo la unidad

entre las dos clases.

Es una representación más fiel

de la distribución de los individuos  
en estas clases.

Por lo tanto, frecuencias relativas  
si las clases tienen la misma anchura

e histograma de densidad  
si las clases son diferentes.

Vamos a ver otro ejemplo.

Usaremos pocos datos  
para simplificar.

Tenemos estos valores.

Primero observaremos el mínimo,  
que es 11, y el máximo, que es 56.

Por lo tanto, sería razonable  
distribuirlo por decenas.

Del 10 al 20, etc.  
Tendremos clases de la misma anchura

y todo será más sencillo.

Tendremos que calcular  
la frecuencia absoluta de cada clase

y la frecuencia relativa.

Y esto ya daría lugar, ahora,

después de ver los tres valores

de la primera clase,

a hacer un histograma de frecuencias:

entre 10 y 20 hay 3,  
entre 20 y 30 hay 1,

entre 30 y 40 hay 3...  
Iríamos representando esta situación.

Se ve aquí una clase  
un poco más relevante

y aquí un hueco,  
entre 40 y 50 no tenemos nada.

Bien, una vez hecho el histograma,

se suelen comentar  
algunos aspectos importantes

como la simetría.  
Un histograma es simétrico

cuando los dos lados son similares.

Aquí tendríamos una asimetría  
hacia la derecha,

una cola hacia la derecha,

y aquí una hacia la izquierda,  
una cola a la izquierda.

Respecto a las modas,  
se suele comentar si es unimodal,

por ejemplo, si una clase  
está claramente más repetida.

O bien este, por ejemplo,  
que es bimodal.

Aquí hay dos clases que tienen  
más relevancia que las otras.

Estos son los aspectos básicos  
que hay que destacar

en un histograma  
una vez lo tengamos representado.

Y con esto acabamos la introducción  
a la estadística descriptiva.

A continuación,

un vídeo tratará  
de los resúmenes numéricos.