

Estadística descriptiva: Medidas de dispersión

Continuamos con este tercer vídeo

dedicado
a la estadística descriptiva.

Concretamente, nos concentraremos

en las llamadas
medidas de dispersión.

A continuación, aprenderemos
a asignar, calcular e interpretar

diferentes indicadores numéricos
que nos ayudan a describir

cómo se distribuyen los datos
alrededor del centro.

Evidentemente, la distribución
depende de qué entendemos por centro.

Si el centro
viene representado por la mediana,

normalmente, usaremos los cuartiles
y los cinco números resumen

y un buen gráfico será el *boxplot*.

En cambio, si el centro
viene representado por la media,

la dispersión
se suele calcular con la varianza

y con la desviación típica
o estándar,

que son indicadores muy usados,

mayormente,
en caso de variables numéricas

y, sobre todo, las continuas.

La idea de cuartil
proviene del interés en dividir...

Estamos hablando ahora de la mediana

y veremos cómo ayudar
a entender la mediana.

La idea de cuartil
proviene del interés

en dividir los datos en cuatro grupos

con aproximadamente
el mismo número de individuos.

Se llaman cuartiles
porque son cuatro zonas.

El primer cuartil

sería esta zona de aquí.

Está definido de manera

que al menos el 25 por ciento
de las observaciones

son menores o iguales y al menos
el 75 por ciento son más grandes.

En realidad, es como si tuviésemos
distribuidas cada una de ellas

en cuatro partes
con al menos el 25 por ciento.

Q sub 1...

delimita el primer trozo,
entre Q sub 1 y la mediana

hay otro 25 por ciento,
entre Q sub 2 y el tercer cuartil

hay otro 25 por ciento
y entre Q sub 3 y el máximo

tenemos el otro 25 por ciento.

Cada uno de estos trozos
representa el 25 por ciento.

Es, por lo tanto,
distribuirlos en cuatro grupos

aproximadamente iguales.

¿Cómo lo haremos
para calcular los cuartiles?

Para calcularlos,

ordenaremos las observaciones
en sentido ascendente,

calcularemos

la posición central y la mediana

y las distribuiremos
en dos grupos iguales:

las que ocupan una posición
más pequeña que N más 1 partido por 2

y las que ocupan una posición
más grande que N más 1 partido por 2.

Una vez hecho esto,

volveremos a calcular la mediana

y el primer cuartil será
la mediana de este primer grupo

que están en una posición
más pequeña que N más 1 partido por 2

y Q sub 3, el tercer cuartil,

será la mediana
de los de la otra parte,

de los que ocupan una posición
más grande que N más 1 partido por 2.

Es muy sencillo de hacer

si hemos entendido
el cálculo de la mediana.

El rango intercuartílico

es la diferencia
entre Q sub 3 y Q sub 1.

Vamos a poner ahora un ejemplo
para verlo más claramente,

pero antes hay que insistir
en los cinco números resumen,

que son el mínimo, $Q_{sub\ 1}$,
la mediana, $Q_{sub\ 3}$ y el máximo.

Con ellos
se puede dibujar el *boxplot*,

que es este gráfico que tenemos aquí.

Se marcan el mínimo, $Q_{sub\ 1}$,
 $Q_{sub\ 2}$, $Q_{sub\ 3}$ y el máximo,

se hace una caja
que va de $Q_{sub\ 1}$ a $Q_{sub\ 3}$,

se marca en medio la mediana

y luego se estiran
hacia el máximo y el mínimo.

Los programas de ordenador lo hacen,
algunos son diferentes,

en horizontal o en vertical,
pero la idea es esta.

Y vemos cuán estirado está
cada uno de los grupos.

Aquí, por ejemplo,

que entre $Q_{sub\ 1}$
y la mediana hay mucha dispersión,

los valores están muy separados.

Recordemos que aquí y aquí

hay más o menos
el mismo número de individuos

y aquí están más separados,
aquí más apretados

y aquí también apretados
de una manera similar.

Vamos a ver ahora
el cálculo de los cuartiles.

Como en la mediana,

distinguiremos
entre observaciones pares o impares.

Aquí tenemos siete como antes.

Las ordenamos y la mediana
ya hemos visto que era el 5,

que es el que ocupa
la cuarta posición.

Y ahora,
para encontrar los cuartiles,

me fijo en los que están
antes que la mediana,

antes de la cuarta posición,
y hago la mediana, que es el 2.

Y lo mismo con los que ocupan
una posición mayor que la cuarta.

Aquí, la mediana será 6,

la mediana de este grupo.
Por lo tanto, el primer cuartil es 2,

el segundo cuartil es la mediana
y el tercer cuartil es 6.

Tendríamos ya calculados
los cuartiles.

También hay que decir
que los programas de ordenador

a veces difieren
en cómo calcular los cuartiles.

Nosotros lo haremos
siguiendo este procedimiento.

Y, finalmente,
el rango intercuartílico

es la diferencia
entre 6 y 2, que es 4.

Y tendríamos ya
los cuatro números calculados.

Bien, vamos a ver ahora qué pasa
si tenemos ocho observaciones.

Como siempre, las ordenamos

y, si hacemos N más 1 partido por 2,

nos dará 4,5.

Recordemos que la mediana
estaría en la posición 4,5.

Pues lo que hacemos

es coger todos los que están
antes de la posición 4,5

y los que están después
de la posición 4,5.

Y aquí calculamos ahora las medianas.

Aquí, la mediana...

general del grupo es 5,5,
la media entre 5 y 6.

Y ahora hacemos la mediana
de este grupo.

La mediana de este grupo,
como son cuatro,

será el valor
que está en medio, será 3.

Y aquí será la media
entre el 6 y el 9,

el valor que está aquí en medio.

Volvemos a hacer la mediana
de cada uno de estos grupos.

Por lo tanto, $Q_{\text{sub } 3}$,
el tercer cuartil,

será 9 más 6, que son 15,
partido por 2, igual a 7,5.

Este será el tercer cuartil.

Y el rango intercuartílico
será la resta de este menos este:

7,5 menos 3 es 4,5.

Este será el cálculo
del rango intercuartílico

y de los cuartiles.

Aquí aprovecho para hacer

un pequeño diagrama *boxplot*.

Hemos puesto los cuartiles
y la mediana

y, como se ve,
la distribución es parecida,

todos los trozos
son bastante iguales.

Es una distribución
bastante uniforme.

Y el rango intercuartílico
se ve aquí.

Muy bien, vamos a ver ahora

las medidas asociadas a la media.

Si el centro lo hemos calculado
a partir de la media,

normalmente,

la distribución se calcula
con la desviación típica o estándar.

Primero comenzaremos
calculando la varianza,

que es la suma del cuadrado
de las diferencias con la media

dividido
por el número de las observaciones.

O sea, a cada observación
le resto la media y hago el cuadrado.

Esto para todas ellas

y luego lo divido
por el tamaño de la población.

Se puede escribir
en forma de sumatorio

y esta es la forma normal

de escribir la varianza.

En caso de tener
valores repetidos en forma de tabla,

tendremos que multiplicar

por la frecuencia absoluta
de cada valor.

Sería $n \text{ sub } i$ por $x \text{ sub } i$
menos la media al cuadrado

dividido

por el tamaño de la población.

Esto en el caso
de tener datos en forma de tabla.

Hay esta otra fórmula
para la varianza,

que es la suma
de las observaciones al cuadrado

dividido por el tamaño
menos la media al cuadrado.

Esta fórmula también se usa.

Y la desviación típica o estándar
es, simplemente,

la raíz cuadrada de la varianza.

Hay que destacar que en este módulo

hablamos
de la desviación típica poblacional,

dividimos
por el total de la población.

Más adelante,
al hacer inferencia estadística,

se habla
de la desviación típica muestral

y hay que dividir por N menos 1.

Pero esto ya lo comentaremos
en su momento.

De momento,
esta es la fórmula de la varianza.

Vamos a ver un pequeño ejemplo.

Tenemos 1, 3 y 5.
Primero calculamos la media:

la suma dividido por 3, que es 3.
9 dividido por 3 es 3.

¿Cómo lo hacemos ahora
para la varianza?

Pues 1 menos 3 al cuadrado,
3 menos 3 al cuadrado

y 5 menos 3 al cuadrado.

Aquí siempre restamos la media

y luego hacemos el cuadrado.

Si se hacen las operaciones,
da 8 tercios y es la varianza.

Y para encontrar
la desviación típica,

simplemente,
hago la raíz cuadrada de la varianza

y me queda 1,63.

Este sería el resultado
de la desviación típica.

Bien, vamos a continuar
con el ejemplo de los libros

que se habían leído
de Virginia Woolf.

Recordemos los datos:

10 no habían leído ninguno,
esto es un 0,

4 habían leído 1,
otros 5 habían leído 2

y 1 había leído 5.

La media ya la teníamos calculada
y era 0,95.

Ahora calcularemos la varianza.

Recordemos que esta parte de aquí
ya la teníamos calculada

y ahora ampliaremos esta tabla
con nuevos cálculos para la varianza.

$X_{\text{sub } i}$ menos la media al cuadrado:

0 menos 0,95 al cuadrado,
1 menos 0,95 al cuadrado,

2 menos 0,95 al cuadrado
y 5 menos 0,95 al cuadrado.

Esto será la suma de las desviaciones
respecto a la media al cuadrado.

Y ahora hay que ir con cuidado
porque hay unas frecuencias.

Esta desviación se ha dado 10 veces

porque 10 estudiantes
han leído 0 libros.

Por lo tanto, debemos multiplicar 10

por x_i
menos la media al cuadrado.

10 por 0,9025, 4 por esta desviación,

5 por esta desviación
y 1 por esta desviación.

Una vez tenemos hechos
estos productos, hacemos la suma.

Si queréis comprobarlo,
podéis parar el vídeo

y hacer los cálculos,
o hacer una captura de pantalla.

Y con esto tendríamos la varianza,

que es este 30,95
que hemos obtenido aquí

dividido
por los 20 amigos que teníamos.

Por lo tanto, la desviación es 1,545,

que es más grande
incluso que la media,

hay mucha desviación:
muchos leen 0 y 1 lee 5.

Están los datos bastante dispersos.

Muy bien, este sería el ejemplo.

Y ahora,
para calcular la desviación típica,

se tendría que hacer
la raíz cuadrada de esta varianza.

Vamos a hablar un poquitín
de las propiedades de la varianza

igual que hemos hecho con la media.

Aquí destacaremos tres elementos:

si todas las observaciones
tienen el mismo valor,

entonces la varianza
y la desviación estándar valen 0.

No hay dispersión,
todas están en el mismo punto,

no hay separación
y la desviación estándar valdrá 0.

Si sumamos a todas las observaciones
una misma cantidad,

la varianza
y la desviación estándar no varían.

Si lo recordáis,
la media aumentaba en esa cantidad,

pero aquí veremos que la varianza

y la desviación no varían

porque la distribución,
la dispersión, sigue siendo la misma.

En cambio, si multiplicamos
todas las observaciones

por una cantidad,

la varianza es mucho mayor
si la K es mayor que 1

porque se multiplica
por K al cuadrado.

Y la desviación estándar
queda multiplicada

por el valor absoluto de K ,
o sea, si K es negativo,

hemos de quitar el signo.

Por lo tanto,
sí que se modifica bastante

la dispersión porque al multiplicar,
los datos se separan o se juntan.

Hacemos un pequeño resumen:

si todas las observaciones
son iguales, la variabilidad es 0.

Sumar la misma cantidad
a todas las observaciones

tampoco modifica la variabilidad.

Y, finalmente, la multiplicación
sí afecta a la variabilidad

puesto que las observaciones
después de multiplicar

están más separadas
si K es mayor que 1

que antes de multiplicar.
Ahora veremos un caso.

Si K es menor que 1,

las observaciones están más juntas,
por lo tanto, cambia la variabilidad.

Veamos este sencillo ejemplo.

Tenemos 0, 1 y 2.
La media, evidentemente,

es 1: $2 \text{ más } 1 \text{ es } 3$,
dividido por 3 es igual a 1.

La varianza es 2 tercios

y la desviación típica
es la raíz cuadrada de 2 tercios.

¿Qué pasa si sumamos 2?

Todo se desplaza
2 unidades a la derecha,

pero las diferencias
respecto a la media se mantienen.

Por lo tanto, en este caso,

la media ha aumentado en 2,

pero como las posiciones relativas
se mantienen

y las distancias a la media
se han mantenido,

la varianza
y la desviación típica no cambian.

Aquí vemos un poco el cálculo.

Se puede repetir el cálculo
y ver que queda lo mismo.

En cambio, si multiplicamos por 2,

el 0 irá al 0, el 1 irá al 2
y el 2 irá al 4.

Los datos, ahora,
están más separados,

las distancias a la media
se han multiplicado por 2.

Estos 1 de aquí ahora valen 2.

Esto hace que la varianza
haya cambiado.

La media será 2

y, al hacer los cálculos,

he de sumar unas desviaciones
respecto a la media más grandes.

Haciendo los cálculos,
queda 4 por 2 tercios.

Es decir, si multiplicamos por 2,
la varianza queda multiplicada por 4.

Aquí queda multiplicada por 4.

Y, al hacer la raíz cuadrada,

la desviación típica
queda multiplicada por 2,

que es la raíz cuadrada de 4.

Esto pasa porque K
es más grande que 1.

Si K fuese más pequeño que 1,
los datos estarían más apretados

y, por lo tanto, la variabilidad,
la varianza, sería más pequeña.

Bien, como resumen,
si sumamos 2 a todas,

la desviación típica no cambia
y si multiplicamos todas por 2,

la varianza queda multiplicada por 4

y la desviación típica
queda multiplicada por 2.

Este sería un poco el resumen

de cómo afectan
estas transformaciones a la varianza.

Bien, con esto acabamos
esta parte de medidas de dispersión

y haremos
un último vídeo a continuación

sobre algunos temas relacionados
con la estadística descriptiva.