

Teorema del límite central

Estudiaremos, a continuación,
el llamado Teorema del límite central.

Es un resultado esencial
en estadística y probabilidad

y, de hecho, permite el estudio
de la segunda parte del curso,

dedicada a la inferencia estadística.

Recordemos que este vídeo

es un complemento
del resumen conceptual

que encontraréis en el aula

y contiene explicaciones
de los conceptos básicos

y animaciones para ilustrar
los contenidos.

Recomendamos que los visualicéis
teniendo en cuenta los módulos

y el material del aula

para poder continuar
vuestro estudio personal.

Bien, comenzaremos dando
una idea intuitiva del resultado

y comenzaremos por estudiar

la media muestral.

Supongamos que sabemos

que la altura
de los estudiantes de la UOC

sigue una distribución normal
de media 172 cm

y desviación típica
sigma igual a 11 cm.

Es decir, tenemos
toda la población de la UOC.

Hemos mirado las alturas
de $x_{\text{sub } 1}$, 179; $x_{\text{sub } 2}$...

La altura de todos ellos.

Y hemos constatado que siguen
una distribución normal

con 172 cm de media

y *sigma* de desviación típica.

Ahora tomamos diferentes muestras
de diez individuos.

Empezamos tomando muestras.

Tomo una muestra

y calculo la media de las alturas
de esta muestra.

Otra muestra

y la media de estas alturas.

Y voy haciendo así
con muchas muestras.

Esto, recogiendo
todos estos valores,

dará lugar
a una nueva variable aleatoria,

que es la media muestral

obtenida sumando diez alturas
dividiendo por diez.

Esta es, pues, la media muestral.

¿Y qué características tiene?

Voy a introducirlas y luego
ya las trabajaremos con más detalle.

Sigue también
una distribución normal,

y, además, la media es la misma
que teníamos antes, 172.

Esto es razonable.

Si hacemos la media
de todas las medias,

acabará saliendo
un mismo resultado que tenía.

Lo que es importante

es ver que la desviación típica
será más pequeña.

Concretamente,
la nueva desviación típica

será 11 dividido por raíz de 10,

por la raíz cuadrada
del tamaño de las muestras.

¿Por qué?

Porque al hacer la media,

se compensará en valores
grandes y pequeños,

entonces, estarán menos dispersos
los resultados.

Estos resultados
que obtenga de las medias

son menos dispersos.

Concretamente, tienen
esta desviación típica,

dividiendo por la raíz cuadrada
del tamaño de la muestra.

Bien, esto es, intuitivamente,
el resultado

y ahora vamos a ver las definiciones
un poco más detalladas

y a hacer
algunos ejemplos numéricos.

Bien, por lo tanto, la media muestral es una variable aleatoria

que se obtiene haciendo la media aritmética de una muestra

de variables aleatorias,

que han de ser independientes con la misma distribución.

En este caso, teníamos la suma de las alturas.

Sumo las variables aleatorias y divido por n .

Si se conoce σ ,

se define el error estándar de la media muestral

como σ dividido por la raíz cuadrada

del tamaño de la muestra.

Y ya he comentado que el error estándar es cada vez más pequeño

cuanto más grande es el tamaño de la muestra.

porque estamos dividiendo por raíz el tamaño de la muestra.

Bien, vamos a ver un poco más de detalle.

Concretamente,
si conocemos la media

y la desviación típica σ ,

entonces esta media muestral

sigue, como ya hemos dicho,
la misma media

y desviación típica σ
partido por raíz de n ,

donde n es el tamaño de la muestra.

Ahora, si hacemos algunos cálculos,

si estandarizamos la media muestral,

es decir, restamos su media

y dividimos por su desviación típica,

obtengo una normal 0,1.

Haciendo un poco de cálculo,

podemos despejar aquí

la suma de las variables aleatorias,

y encontraré que esta suma

sigue una normal de media
 $\bar{x}$ por la media

y desviación típica

raíz de n por *sigma*.

Y, por lo tanto, si estandarizamos,

cojo la suma, resto la media
y divido por la desviación típica,

tendré que esto sigue
una normal estándar 0,1.

Estas son las distribuciones

con las que vamos a poder trabajar

a partir de estos resultados.

Vamos ahora
con un ejemplo concreto.

Seguimos con las alturas
de los estudiantes de la UOC.

Sabemos que tiene
una media de 172 cm

y desviación típica 11 cm.

Y ahora hemos tomado una media
de 300 estudiantes.

Nos podemos preguntar
cuál es la probabilidad

de que la media de las alturas
de la muestra,

es decir, cuál es la probabilidad
de que el resultado obtenido

a partir de esta muestra

sea menor que 170.

¿Qué es lo primero
que tenemos que hacer?

Aplicar el teorema

y ver que la distribución
de la media muestral

será 172,

la media será 172 cm,

y la desviación típica *sigma*
partido por raíz de *n*,

11 partido por raíz de 300,

es decir, 0,635.

Esta será la nueva desviación típica.

Y ahora hacemos
los cálculos normales.

La probabilidad
de que la media muestral

sea menor que 170,

estandarizo,

resto la media
dividida por la desviación típica

y obtengo estos resultados.

Aquí tengo una normal,
la Z , la normal estándar

y este resultado me da -3,149.

Si calculamos esta probabilidad,

el resultado es 0,0008.

Es una probabilidad muy baja,

porque como ahora
la desviación típica es muy pequeña,

estoy muy alejado de la media.

Estoy tres desviaciones estándar
por debajo de la media.

Por lo tanto, la probabilidad
será muy pequeña

de obtener esta media muestral
inferior a 170.

Bien. Vamos a ver ahora...

Empezaremos el estudio del caso
cuando la *sigma* no es conocida.

Y en este caso,
necesitamos otra distribución nueva.

Concretamente, la llamada
distribución t de Student.

Es una distribución,

de hecho, no es una, son muchas.

Tenemos una distribución
 t de Student

para cada grado de libertad.

Podemos tener una distribución
 t de Student de 10 grados de libertad,

de 20 grados de libertad,
de 3 grados de libertad, etc.

Para cada grado de libertad,
tenemos una t de Student.

Es similar a la normal estándar.

Es simétrica en torno al cero,

pero la desviación típica
es un poco mayor

que la normal estándar.

Sin embargo, cuanto más grande
es el número de grados de libertad,

más se aproxima

la t a la normal.

Aquí vemos unos cuantos dibujos.

df quiere decir "grados de libertad".

Aquí tenemos la de un grado
de libertad,

la de 2 grados de libertad, la de 4,

y si cogiésemos
infinitos grados de libertad,

sería la distribución normal.

De hecho, consideramos
que podemos aproximar

la distribución t de Student
por una normal

cuando n es más grande que 100.

Y para los grados de libertad
mayores que cien,

la Student de n grados de libertad

se parece a la normal.

Bien, cuando la desviación típica
poblacional es desconocida,

lo que haremos es calcular
la desviación típica muestral

con la fórmula de siempre.

La suma de x sub i
menos la media al cuadrado

dividido por n menos uno

y la raíz cuadrada.

La fórmula normal

de la desviación típica muestral.

Y en este caso, el error estándar

es como antes,
pero en vez de *sigma*, ponemos *s*.

s dividido por raíz de *n*.

Y resulta
que si la variable que estudiamos

sigue una distribución normal
con media *mu*

y desviación típica desconocida,

entonces, la media muestral
menos *mu* dividido por *s*

raíz de *n*,

sigue una distribución *t* de Student

de *n* -1 grados de libertad.

No sigue, en este caso, una normal.

Cambiando la *sigma* por *s*,

provoca que aparezca
la distribución *t* de Student

con *n* -1 grados de libertad.

Observad que cuando conocemos
la desviación típica poblacional

la media muestral
sigue una distribución normal,

y cuando es desconocida,
sigue una t de Student.

De todas formas, cuando el tamaño
de la muestra es muy grande

o suficientemente grande,

consideramos que n
sea mayor que 30,

siempre se puede aproximar
directamente

por la distribución normal.

Bien.

¿Cuál es el resultado general?

Bueno, es un poco más general
de lo que hemos hecho

y el teorema del límite central dice

que si una muestra
es suficientemente grande,

sea cual sea la distribución
de la variable de interés,

no hace falta que sea normal,

la distribución de la media muestral

será aproximadamente normal.

Es decir, la media muestral
de cosas que no son normales

acaba siendo normal

con la misma media
que la variable de interés

y desviación típica el error estándar.

Siempre que la muestra
sea suficientemente grande.

En otras palabras,

dada cualquier variable aleatoria x
con esperanza μ y n grande,

la distribución
de la media muestral menos μ

dividido por error estándar

es una normal estándar.

¿Y cuándo será
suficientemente grande?

Normalmente, cuando n
sea más grande que 30.

Y el error estándar se calculará
como s dividido por la raíz de n .

Esto es un poco la esencia
del teorema del límite central

que ya hemos ilustrado con ejemplos

anteriormente.

¿Casos particulares?

Bueno, pues vamos a ver

la aproximación
de la binomial a la normal.

Si x es una variable aleatoria
con distribución binomial,

y la n también
es suficientemente grande,

entonces resulta que x
ya es directamente

muy parecida a la normal.

¿Con qué esperanza? La misma:
 np y varianza $np(1-p)$.

En este caso, si n
es suficientemente grande,

significa que n por p
y n por $p(1-p)$

han de ser los dos
mayores que cinco.

O bien directamente,
como hemos comentado antes,

que la n sea 30.

Este es el caso de la aproximación
de la binomial a la normal.

Y con esto

podemos aplicarlo
al estudio de la proporción.

Una proporción
corresponde a hacer la media

de n variables aleatorias
de Bernoulli de parámetro p ,

o lo que es lo mismo,
a dividir por n una binomial.

Esto es un poco teórico,

pero la aplicación
es muy concreta y muy sencilla.

Cuando n es suficientemente grande,

la distribución
de la proporción muestral

es aproximadamente normal.

Y tiene como media la proporción

y como varianza, en este caso,
 p por 1 menos p dividido por n .

Este sería el caso
de la proporción muestral.

Y vamos a ver un ejemplo.

Se hacen encuestas
de un determinado tema

y tiene dos opciones: A y B .

La probabilidad de que un individuo concreto opine A es p ,

y n será el número de encuestas hechas.

Hemos preguntado a 400 habitantes, esto será la n .

Y encontramos que el 30 % opina A , esto será la p ,

porque hemos obtenido este resultado de esta proporción.

Es decir, podemos establecer, como he comentado,

que p es 0,3.

Entonces, la distribución de la proporción de habitantes

que opina A

sigue una distribución normal 0,3

y varianza
0,3 por 1 menos 0,3 dividido por 400.

Es decir, será una normal de 0,3,0.0005.

Esta es la distribución de la proporción muestral.

Y con esto

ya podemos calcular probabilidades.

Para calcular la probabilidad
de que una muestra...

De que en una muestra

la proporción de habitantes
que opinan A

sea mayor que el 40 %,

tenemos que calcular la probabilidad
de que la proporción muestral

sea mayor que 0,4

y aplicamos la ley
que acabamos de describir.

Lo estandarizo, $-0,3$,

dividido por la raíz cuadrada
de la variante A .

Y hago $0,4$ menos $0,3$ dividido
por la raíz cuadrada de la variante A .

Con esto obtengo una normal aquí

y aquí el valor $4,47$.

Si miro ahora

cuál es la probabilidad

de que una normal estándar
sea mayor que $4,47$,

obtengo un valor
de aproximadamente 0.

Está muy alejado del centro,
de la media.

Por lo tanto, la probabilidad
de encontrar una muestra

con estas características,
es prácticamente nula.

Y con esto acabamos
el ejemplo de la proporción

y acabamos

la introducción que hemos hecho
del teorema del límite central,

un resultado importantísimo
para la probabilidad y la estadística.