

Contraste de dos muestras

Continuamos
el estudio de la estadística

con el tema
de contraste de dos muestras.

Es una continuación
del tema de contraste de hipótesis.

Las ideas son las mismas,

solo cambian los problemas

porque ahora
tendremos datos de dos muestras.

Tendremos que ver cómo calcular
el estadístico de contraste.

Será diferente,

pero el funcionamiento del p-valor

y de los valores críticos
será muy similar.

Por lo tanto,
aquí solo comentaré las diferencias

y veremos cómo calcular

cada uno de los elementos
que necesitamos.

Recordemos que este vídeo
es un complemento

del material que tenéis en el aula

y es conveniente
visualizarlo junto al material

para poder facilitar
vuestro estudio personal.

Bien, comenzaremos estudiando
el contraste de diferencia de medias.

Ahora consideraremos dos muestras
de tamaño n_1 y n_2

que provienen cada una
de una distribución normal.

La primera muestra
proviene de una distribución normal

de media μ_1
y varianza σ_1^2 al cuadrado

y la segunda,
de una distribución normal

de media μ_2
y varianza σ_2^2 al cuadrado.

¿Qué contrastes nos podemos plantear?

La hipótesis nula
siempre es de igualdad de medias.

Nos estamos planteando
si estas dos medias son iguales.

La hipótesis alternativa
puede ser bilateral,

que las medias sean diferentes,

o unilateral, que la primera
sea menor que la segunda

o que la primera
sea mayor que la segunda.

Estas son las tres posibilidades
que tenemos

en cuanto a hipótesis alternativa.

¿Cómo responderemos a esta pregunta?

Primero fijaremos
el nivel de significación *alfa*

y obtendremos las medias muestrales,

que nos permitirán conocer algo
de las medias poblacionales.

Y calcularemos
el estadístico de contraste.

En el caso de las varianzas
poblacionales conocidas,

suponiendo que conocemos
estos dos parámetros,

el estadístico de contraste es z^* :

la diferencia
de las medias muestrales

dividido por la raíz

de la varianza primera

partido por el tamaño de la muestra
más la segunda varianza

partido por el tamaño
de la segunda muestra.

Y esto constituye una observación
de una distribución normal $(0,1)$,

evidentemente,
suponiendo la hipótesis nula.

Por lo tanto, este será el caso

del cálculo
del estadístico de contraste

cuando las varianzas poblacionales
son conocidas.

Bien, ¿qué pasará
si no conocemos estas dos varianzas?

Pues es el caso de las varianzas
poblacionales desconocidas,

pero supondremos que son iguales.

En este caso,
hemos de suponer, adicionalmente,

que las varianzas,
estas dos de aquí, son iguales.

Es un poco raro
suponer que son iguales,

pero hay maneras de averiguar

si son iguales

aunque no sepamos
exactamente su valor.

Bien, lo que tenemos que hacer
es sustituir este denominador

donde aparecen
 σ_1 y σ_2 al cuadrado,

que no conocemos,
por este denominador de aquí

donde la s se calcula
de esta manera. Es un poco largo:

$n_1 - 1$
por s_1 al cuadrado

más $n_2 - 1$
por s_2 al cuadrado

dividido por n_1
más n_2 ,

donde s_1 y s_2
son las desviaciones típicas,

pero muestrales, de la muestra.

Ya que no conocemos
 σ_1 y σ_2 ,

utilizaremos s_1 y s_2 ,
las de la muestra.

Y esto da lugar
a una distribución t de Student

con, curiosamente,

$n - 1$ más $n - 2$ menos 2
grados de libertad.

Es decir,
sumamos los tamaños de la muestra

y restamos 2.

Aquí tendremos, pues,
nuestra distribución t de Student.

Bien, vamos a ver ahora,
una vez ya planteado esto,

cuál es la hipótesis correcta.

Esto es un poco un recordatorio

de lo que hicimos
en el caso de contraste de hipótesis.

Si queremos usar el p -valor,
¿qué tenemos que hacer?

En el caso de varianzas
poblacionales conocidas

en que la distribución es una normal,

calcularemos, si la hipótesis
alternativa es bilateral,

la probabilidad
de que la variable aleatoria

esté más alejada
que el estadístico de contraste.

Si es unilateral de más pequeño,

calcularemos
la probabilidad de que la Z

sea menor
que el estadístico de contraste

y si es unilateral de mayor,

calcularemos
la probabilidad de que la Z

sea mayor
que el estadístico de contraste.

Una vez calculada esta p ,
si es muy pequeña,

si es menor
que el nivel de significación,

rechazaremos H_0 .

¿Por qué? Porque es un valor
muy poco probable.

Esto nos hace pensar que H_0
no será cierta.

¿Cómo sería
en el caso de los valores críticos?

A partir de los valores críticos,

en el caso de la hipótesis
alternativa bilateral,

hay que calcular

z sub α medios. ¿Por qué?

Porque ha de dejar, en total, α .

A un lado y a otro ha de dejar α

y, por lo tanto, ha de dejar
 α medios a cada lado.

En el caso de la hipótesis
alternativa de menor,

tenemos que $-z$ sub α
es aquel valor

que deja, a su izquierda, α .

Y, en el caso de la hipótesis
alternativa de mayor,

z sub α es aquel valor
que deja, a la derecha, α .

¿Y cómo decidiremos?

Si el estadístico de contraste
está en las zonas rojas,

si está más alejado
de los valores críticos,

entonces rechazaremos
la hipótesis nula.

Si tengo aquí
el estadístico de contraste,

rechazaremos la hipótesis nula

o bien si lo tengo aquí,
en el caso de menor,

o aquí, en el caso bilateral.

Estas son las mismas ideas
que teníamos,

pero ahora en el caso
de tener dos muestras.

¿Cómo lo haríamos

en el caso de varianzas poblacionales
desconocidas, pero iguales?

Funciona igual,
pero hay que sustituir la z

por esta t de $n - 1$ más $n - 2$
menos 2 grados de libertad.

Es lo mismo, pero sustituyendo
la z por esta t de Student.

La idea es la misma

y la idea de rechazo
también es la misma.

Vamos a ver ya un ejemplo.

Imaginemos que tenemos
un fabricante de bombillas

que asegura
que sus bombillas duran más

que las de una nueva marca.

Aquí tenemos ya dos muestras,
dos poblaciones.

Conseguimos 25 bombillas
del fabricante

y 15 bombillas de la nueva marca.

Obtenemos la primera media

de la duración de las bombillas
del fabricante, que es 827,

y su varianza muestral.

Y, en cambio, la nueva marca
tiene una media de 812

y una varianza muestral

de 7,984.

Estas serían
las varianzas muestrales.

Ahora haremos una suposición extra.

Supondremos que las poblaciones

se distribuyen normalmente
con varianzas iguales y desconocidas.

En este caso, no conocemos
las varianzas poblacionales

y queremos contrastar,

con un nivel

de significación del 0,05,

si el fabricante tiene razón.

La hipótesis nula
es la igualdad de medias

y la hipótesis alternativa
es que las bombillas del fabricante

duran más
que las de la segunda marca.

El nivel de significación
ya nos viene dado

y el estadístico de contraste

se calcula
a partir de los datos que tenemos.

Como no conocemos
las varianzas poblacionales,

será una distribución t ,
en este caso,

de 25 más 15 menos 2,
38 grados de libertad.

¿Y cómo se calcula?

Pues restamos las medias

y el denominador
es un poco más complicado

porque hay que calcular
primero esta s .

Esta s se calcula a partir...

de las varianzas de la muestra.

Primero calcularemos esta s

a partir
de las varianzas de la muestra

y los tamaños de la población

y luego lo pondremos
en el denominador

multiplicado por la raíz
de 1 partido por $n - 1$

más 1 partido por $n - 2$,
por los tamaños de las muestras.

Con esto ya tendremos
el estadístico de contraste,

que es 15,64.

Y ahora vamos a ver cómo decidimos.

El principio es el mismo
para tener presente el enunciado,

pero ahora continuamos
a partir de aquí,

a partir de este valor.
¿Cómo lo hacemos para decidir?

Podemos mirar el p-valor.

El p-valor será la probabilidad

de que la t sub 38
sea mayor que esto de aquí,

sea mayor que 15,64.

Lo podemos poner en R
y sería la función pt

y, si calculamos esta probabilidad
de que sea mayor,

nos da aproximadamente 0.

También podemos mirar
el valor crítico.

El valor crítico lo podemos calcular
con la función qt .

El valor crítico de 0,05
con estos 38 grados de libertad

es 1,68. ¿Qué nos encontramos?

Que el estadístico de contraste
es mucho mayor que el valor crítico.

Por lo tanto,
tanto en un caso como en otro,

rechazamos la hipótesis nula,

es decir, la duración no es la misma.

Tiene razón el fabricante
diciendo que las de su marca

duran más que las de la otra marca.

Este es un caso sencillo

donde aplicar
un contraste de dos muestras

sobre la media.

¿Qué pasa si las muestras
no son normales?

Hasta ahora hemos trabajado
con muestras normales.

Si no son normales,
pero son superiores a 30,

si el tamaño de las muestras
es superior a 30,

se puede hacer casi lo mismo.
Solo hay que sustituir

las varianzas poblacionales
por las varianzas muestrales.

Y, en este caso,
tenemos un estadístico de contraste

que sigue una normal.

Pero esto solo lo podremos hacer
si las muestras son superiores a 30.

Recordemos: sustituimos
las varianzas poblacionales

por las varianzas de la muestra.

Es muy sencillo y el funcionamiento
es el mismo que antes.

Bien, a partir de esto,

podríamos hacer
intervalos de confianza.

Estas son solo las fórmulas
y las comentaré muy brevemente.

Tendremos siempre la diferencia
de las medias muestrales

y luego, si las varianzas
poblacionales son conocidas,

será una z y el error estándar

lo calcularé a partir
de las varianzas poblacionales.

En el caso
de las poblaciones normales

con varianzas poblacionales
desconocidas, pero iguales,

aquí tendríamos la t

de n_1 más n_2
menos 2 grados de libertad

y el error estándar sería
este producto que ya hemos comentado

calculado a partir
de las varianzas muestrales

y los tamaños de las muestras.

Y, en el caso
de muestras grandes no normales,

muestras de tamaño superior a 30,

tenemos la diferencia de las medias,
la z y el error estándar,

que se calcula
a partir de las varianzas muestrales,

a partir de las varianzas
obtenidas en la muestra.

Con esto
haríamos los intervalos de confianza

como los hemos hecho siempre.

Veremos ahora

un caso de un intervalo de confianza.

Vamos a retomar el ejemplo
del fabricante de bombillas.

Haremos un intervalo de confianza
con el 95 por ciento.

Primero calcularemos
la diferencia de medias

y el error estándar.

Los valores críticos

serán 2,0244

por ser esta t .

Y, a partir
de la diferencia de medias,

con este valor crítico

y con el valor
que ya teníamos de la s ,

obtendremos este intervalo de aquí.

Aquí están los detalles
de los cálculos

y obtenemos este intervalo.

¿Qué observamos?

Que no contiene el valor 0,

contiene valores positivos,
por lo tanto,

el primer fabricante
produce bombillas

que duran más
que las de la nueva marca.

Es lo mismo que habíamos obtenido
con el contraste de hipótesis.

Los valores críticos,
si tenéis curiosidad,

se pueden calcular
con la función qt de R

a partir de esta instrucción de aquí.
Como vemos, es lo mismo,

pero utilizando ahora
un intervalo de confianza.

Bien, vamos a ver ahora un contraste
sobre la diferencia de proporciones.

Ahora ya no tendremos medias
de valores de una población,

sino proporciones.

Tendremos dos muestras,
de tamaños $n_{\text{sub } 1}$ y $n_{\text{sub } 2}$,

que provienen
de distribuciones Bernoulli

de parámetros $p_{\text{sub } 1}$ y $p_{\text{sub } 2}$.

Estas serán
las proporciones de la población.

Y las proporciones muestrales

son $p_{\text{sub } 1}$ con sombrero
y $p_{\text{sub } 2}$ con sombrero.

Las hipótesis pueden ser:
igualdad de proporciones,

proporciones diferentes,

primera proporción
menor que la segunda

y primera proporción
mayor que la segunda.

Fijamos
un nivel de significación α

y el estadístico de contraste
es, simplemente,

la diferencia
de las proporciones muestrales

dividido por esta s sub p ,
este error estándar de la proporción,

que se calcula de esta manera:

calculamos primero
una proporción común,

que es n sub 1 por la proporción 1

más n sub 2
por la proporción muestral 2

dividido por la suma
de los tamaños de las muestras.

Y s sub p ,
esta especie de desviación,

una especie
de desviación de la proporción,

se calcula así:

la proporción común
por 1 menos la proporción común

dividido por n sub 1

más esta proporción común

por 1 menos la proporción común
dividido por n sub 2.

La fórmula es larga,
pero solo hay que saber

qué ponemos en cada sitio.

Aquí tenemos
las proporciones de las muestras

y aquí esta proporción común.

Por tanto, con esto calcularemos
el estadístico de contraste.

Y esto será una distribución normal
bajo la hipótesis nula,

una distribución normal (0,1).

Bien, esta transparencia
ya la hemos visto antes:

cómo calcularemos el valor crítico
y cómo calcularemos el p-valor.

En este caso,
como es una distribución z ,

es lo de siempre,
es el mismo caso de antes.

¿Cuál sería
el intervalo de confianza?

Es la diferencia
de las proporciones muestrales

por el valor crítico
y por este error estándar

que, como hemos visto,
se calcula de esta manera:

la proporción común
y este error estándar

que se puede calcular así,
es solo un tema de cálculo.

Bien, veremos un ejemplo

de intervalos de confianza
y de contraste de hipótesis

para diferenciar proporciones.

Imaginemos que se quiere construir
una central nuclear

cerca de un pueblo
y se hace una encuesta

a los habitantes del pueblo
y otra a los del resto de la comarca.

Los resultados son los siguientes:

en el pueblo, 120 de 200

están de acuerdo en construirla

y, sin embargo, en la comarca,
240 de 500 están de acuerdo.

Vamos a ver si la proporción es igual

o bien si la proporción
de los que están a favor en el pueblo

es más grande que la proporción
de los de la comarca.

Queremos saber si los del pueblo

están más interesados en la central
que los de la comarca.

¿Cuál es la hipótesis nula?

La podemos escribir así:
igualdad de proporciones,

$p_{\text{sub } 1} - p_{\text{sub } 2} = 0$.

Y la alternativa
será $p_{\text{sub } 1} > p_{\text{sub } 2}$.

$P_{\text{sub } 1}$ es la población del pueblo.

El nivel de significación es 0,05.

¿Y el estadístico de contraste?
¿Qué tenemos que hacer?

Primero, la proporción del pueblo:
120 partido por 200, 0,60.

El 60 por ciento de los habitantes
del pueblo están de acuerdo.

En la comarca,
es 240 partido por 500, 0,48.

En la comarca,

la proporción es menor.

¿Qué calcularemos?

Pues ahora calculamos
esta especie de proporción común:

n_1 por p_1
más n_2 por p_2

dividido por la suma
de los tamaños de las muestras

y da 0,514.

A nivel global,

es como si la proporción
fuese de un 51,4 por ciento.

Calculamos s_p con sombrero

con este 0,514. Hacemos los cálculos

y da 0,0418.

Y, finalmente,

hacemos la diferencia
de las proporciones

dividido por este error estándar,
por s_p con sombrero,

y me da 2,87,

que es una observación
de una variable normal (0,1).

Es un valor bastante alto.

Imagino que no habrá dudas,
solo es poner en las fórmulas

los valores correspondientes.

Esto está resuelto
en las notas de estudio

y lo podéis comprobar.

Ahora veremos cómo decidimos.

Vamos a calcular el p-valor.

El p-valor, como queremos saber

si la proporción del pueblo
es mayor que la de la comarca,

es la probabilidad de que Z sea mayor
que el estadístico de contraste.

Y es 0,0021, menor que 0,05.

Entonces, podemos rechazar H_0

y decir que, realmente,

la proporción en el pueblo
es superior que en la comarca.

Podríamos hacer también
un intervalo de confianza.

Ya tenemos $s_{\hat{p}}$ con sombrero,
tenemos $z_{\alpha/2}$ medios

y tenemos
la diferencia de las proporciones.

El intervalo de confianza
es $(0,03, 0,2)$.

Vemos que el 0 no está
en este intervalo de confianza,

por lo tanto, la proporción es mayor
en el pueblo que en la comarca.

De las dos maneras
llegamos a la misma conclusión.

Todo esto en lo referente
a la diferencia de proporciones.

Y con esto hemos acabado
el tema de contraste de dos muestras.

Las ideas son las mismas
que en el contraste de hipótesis.

Hemos repasado también
las maneras de decidir.

Solo cambia cómo calculamos
el estadístico de contraste

y cómo calculamos
los valores críticos

dependiendo de la distribución
que haya que usar en cada caso.