

Regresión lineal simple

Estudiaremos, en este vídeo,
el tema de regresión lineal simple.

Recordemos
que el vídeo es un complemento

del correspondiente módulo

del material que encontraréis
en el aula.

Es importante
visualizarlo conjuntamente

para facilitar
vuestro estudio personal.

Bien, el objetivo que tenemos
en este módulo

es explicar el comportamiento
de una variable,

normalmente la Y ,
que será la variable dependiente,

a partir de otra variable,
que denotaremos con X

y será la variable independiente.

Vamos a estudiar qué relación hay
entre parejas de variables.

Por ejemplo, podemos investigar

la relación
entre los ingresos mensuales

y los gastos en actividades de ocio.

Normalmente,
lo razonable sería considerar

que la variable X son los ingresos.

Lo lógico es pensar que los ingresos,
de alguna manera,

determinan la variable Y
y la variable dependiente,

que serían los gastos.

Lo que podríamos hacer
es ir buscando,

comprobando diferentes valores
de diferentes meses

y encontrar parejas
de ingresos-gastos.

El objetivo es ver

cómo resumir estas parejas

utilizando, si es posible, una recta.

Bien, por lo tanto,

a partir de este conjunto
de observaciones, de la X y de la Y ,

sobre una muestra de individuos,

lo que haremos es representar
estos datos, como he dicho antes,

de una manera bastante informal.

Con ello obtendremos un diagrama
de dispersión o nube de puntos.

Esta nube de puntos ya nos informa
un poco de la distribución.

Aquí vemos como prácticamente
todos los puntos

están sobre una recta.

Aquí también.
Una recta creciente, en este caso.

Aquí ya se ve que los puntos
no siguen un modelo lineal,

más bien sería como una parábola.

Aquí no hay ningún patrón
visible, reconocible.

Parece que llenan un círculo,

pero no siguen ni un modelo lineal
ni uno cuadrático.

Aquí sí que habría una recta
más o menos que resuma,

pero claro,
peor que en los casos A y B.

Y en este caso, F,

también parece que hay
un poco de tendencia creciente,

pero no se ve muy claro

si habría alguna recta
que ayude a resumir estos datos.

Por lo tanto, nuestro objetivo será
tanto encontrar una recta

que resuma los datos,

como ver si es un buen resumen.

Hasta qué punto

estos datos se adaptan
a una recta en concreto.

Bien, una vez hecho
el diagrama de dispersión,

el objetivo de este módulo
es encontrar una relación lineal.

Es decir, vamos a concentrarnos

en encontrar una relación
en forma de recta.

Y esta recta será la llamada
"recta de regresión".

Recordemos que una recta
queda determinada por la pendiente,

que llamaremos b ,

y por la ordenada en el origen,
que llamaremos a ,

con lo cual tendremos
una ecuación de este tipo:

y igual a a más bx .

Y comenzaremos definiendo
un concepto básico.

Dos conceptos básicos,

que son el valor estimado
y el residuo.

¿Qué es el valor estimado?

El valor estimado
es lo que le corresponderá a la x

usando la recta de regresión.

Lo escribiremos
con acento circunflejo,

a veces diré "como un sombrero",

y será el valor estimado
correspondiente a x sub i .

En este caso,
si partimos de x sub i ,

el valor estimado
es el que está en la recta.

Este sería el valor estimado
y con sombrero.

En cambio, aquí tengo
el valor real de la observación.

Los valores reales
serán y_i

y el valor estimado será $\hat{y}_i$,

pero con sombrero,
por decirlo de alguna manera.

Y una vez tengo,
para cada observación,

estos dos valores: el real
de la observación y el estimado,

tendremos lo que se llama
el residuo.

El residuo es la diferencia
entre el valor real y el valor estimado.

Se puede hacer esta recta de aquí,

que daría $\hat{y}_i$ menos a
más $b x_i$.

Este es el valor de la recta.

Por lo tanto, el valor observado

menos el valor
que le corresponde en la recta

al punto x_i .

Esto son dos conceptos básicos:
estimado y el residuo.

Muy bien, con esto ya podemos
describir el método que utilizaremos

para encontrar la recta de regresión.

Utilizaremos el llamado método
de los mínimos cuadrados.

¿De qué se trata? Se trata de ver

que la suma de los cuadrados
de los residuos

sea lo mínimo posible.

Vamos a hacerlo.
Ya lo hemos hecho en algunos casos,

trabajar con el cuadrado
de las desviaciones.

O sea, ahora trabajaremos
con el cuadrado de los residuos.

Veremos que la suma
del cuadrado de los residuos

sea lo mínimo posible.

Haciendo
un poco de cálculo diferencial,

se llega a las ecuaciones normales,

no vamos a entrar en detalle,

y a partir de ellas
ya se pueden encontrar

los parámetros de la recta.

Recordemos que la recta de regresión
sería y igual a a más bx .

¿Y cómo se calcula?
Pues la b se calcula

haciendo este cociente:

s_{xy} dividido por la varianza
al cuadrado.

Esto es la covarianza muestral,
que ahora mismo definiré qué es.

Y la ordenada en el origen, la a ,

será la media de la y menos b
por la media de la x .

Y la b es esta
que hemos calculado antes.

Por lo tanto, todo empieza
por calcular la b ,

que se obtiene dividiendo
la covarianza muestral,

que es esta fórmula de aquí,
 s_{xy} ,

será la suma de la diferencia
entre x_i y la media

por y sub i y la media de y
dividido por $n-1$.

Hago la suma de los productos,
de las desviaciones

respecto a las medias.

Esto será la covarianza muestral

y la varianza muestral,
ya es conocida de siempre,

es simplemente la diferencia
respecto a la media al cuadrado...

La suma de las diferencias
respecto a la media al cuadrado

dividido por $n-1$.

Con estos dos, ya puedo calcular
la pendiente.

Aquí tengo la s sub xy
y aquí tengo la varianza de x .

Por lo tanto,
con esto ya podré calcular

la pendiente de la recta de regresión.

Y después, a partir de la pendiente,

calculo la ordenada en el origen.

Muy bien.

Simplemente un comentario.

En las notas de estudios
hay un cambio de notación

para distinguir
una recta cualquiera

de la recta de regresión.

En la recta de regresión utilizaremos

esta notación
con el acento circunflejo

o con el sombrero.

y con sombrero,
beta sub 0 con sombrero

más *beta* sub 1 con sombrero por x .

La pendiente, lo mismo.

Lo que antes era la b ,

ahora lo vamos a llamar *beta* sub 1
con sombrero.

La covarianza muestral dividida
por la varianza al cuadrado.

Y lo que era la a ,
lo llamaremos *beta* sub 0,

que es la media de la y
menos el valor de *beta* sub 1

por la media de la x .

Con esto ya tendremos
la ecuación de la recta de regresión.

Vamos a ver un ejemplo. Este ejemplo
está en las notas de estudio.

Voy a explicar un poco
cómo obtenerlo.

Tendremos observaciones
sobre pesos y alturas de 10 personas.

Aquí tengo la información
sobre el individuo 1.

Mide 161 cm y pesa 63 kg.

Aquí, lo lógico es que la X
sea la altura.

Parece que la altura ha de determinar,
de alguna manera, el peso.

Lo que haríamos sería,
en primer lugar,

hacer la nube de puntos.

Vemos que sí que hay
una tendencia positiva

y una recta,
que más o menos podría ser esta,

que parece que se acerca
a todos los puntos.

Vamos a calcular esta recta.
Es muy sencillo.

Hay muchos cálculos,
pero es muy sencillo.

Y lo que se suele hacer
es una tabla.

Tenemos una tabla

primero, con los valores de la X
y los valores de la Y .

Podemos sumar los valores de la X

y sumar los valores de la Y
para encontrar las medias.

Con esto tendremos la media.

Es el primer caso.

La media de x , 1614,
dividido por 10, en este caso.

Y la media de la y , 619,
dividido por 10.

Una vez tenemos estas medias,

podemos hacer las desviaciones
respecto a la media.

A cada valor de la X
le resto su media.

161 menos su media.

Quedaría -0,4.

Y hago lo propio con la Y:
63 menos 61,9.

A cada valor de la Y
le resto su media.

Y con esto
ya podremos calcular también

los cuadrados de las desviaciones.

Sería esta columna de aquí.

Hago los cuadrados
de cada una de las restas

respecto a la media.

Y aquí los cuadrados de la Y:
1,1 al cuadrado, -5,9 al cuadrado, etc.

Y los sumo.

Hago la suma.

¿Esto para qué me servirá?
Para las varianzas.

Ahora tendré que la varianza
es este 476,4

dividido por 10 menos 1, 9,

porque estamos haciendo
la varianza muestral.

Y la varianza de la Y
la obtendré con esta suma, 812,

también dividido por 9,
y me quedará 90,32.

Esta será la varianza de las y .

Siguiente paso:
la covarianza muestral.

Esta columna de aquí

se obtiene multiplicando
estas dos columnas.

La desviación de la x
respecto a la media

por la desviación de la y
respecto a la media,

y también haciendo la suma.

Tengo el 466,
que voy a dividir por 9, también,

y me da el 51,82.

Ahora ya tengo
los dos ingredientes básicos

para calcularlo,

que son la covarianza

y la varianza de las x ,
esta de aquí.

Con esto ya tengo β_1 ,
la pendiente,

que es la covarianza

dividido por la varianza de las x .

Esto sería la pendiente,

y la ordenada en el origen

sería simplemente
la media de las y ,

esta media de la y

menos el cociente
que he encontrado

por la media de las x .

Este sería el valor de β_0 ,
de la ordenada en el origen, -96,1121.

Por lo tanto, con esto ya tengo
la ecuación de la recta de regresión:

-96,1121 más 0,97 x .

Por lo tanto,
esta sería la recta de regresión,

la recta que mejor se adapta
a este conjunto de datos.

Muy bien, hecho el ejemplo rápido,
los cálculos son muy sencillos,

simplemente un poco el orden
en el que hacer estos cálculos

para simplificar el trabajo.

Muy bien. Una vez determinada
la recta de regresión,

es muy importante interpretar
lo que hemos encontrado,

interpretar para qué sirve cada cosa.

Primero, la ordenada al origen,
la *beta* sub 0 con sombrero.

Este parámetro es la estimación
del valor de la *Y*

cuando la *X* es igual a 0.

Es el valor de la *Y*
cuando la *X* vale 0.

Esto no siempre tiene interpretación,

porque hay veces
que no tiene sentido

que la *X* tome el valor 0.

En el caso anterior,
que la *X* sea 0,

sería el peso de una persona
que midiera 0.

En este caso, no tiene sentido.

Pero siempre hay que mirarlo
en el caso que sea adecuado

y sería el valor estimado

cuando la X vale 0.

En cambio, la pendiente
siempre tiene interpretación,

y es una estimación

del incremento de la variable Y
cuando la X aumenta una unidad.

Viene del concepto
de pendiente de una recta.

Por lo tanto, nos informa
de cómo están relacionadas.

Si la pendiente es 2,

quiere decir que cuando la X
aumenta una unidad,

la Y aumenta dos.

Si la pendiente es -5,

quiere decir que cuando la X
aumente uno, la Y baja cinco.

En el ejemplo anterior,

tenemos una pendiente de 0,97.

Eso quiere decir
que por cada centímetro de altura,

el peso aumenta en 0,979 kg.

Es el aumento de la Y
por cada unidad que aumenta la X

y corresponde a la inclinación
de esta recta de aquí.

Muy bien, esta sería
la interpretación de la pendiente.

Y también ahora el uso
de esta recta de regresión.

¿Para qué vamos a utilizar
la recta de regresión?

Bueno, pues es hacer interpolación.

Es decir, predecir el valor
de la variable dependiente

para un valor de la variable
independiente

no observado en la muestra.

Para valores de la X que ya tenemos,
ya sabemos cuál es el valor de la Y ,

pero a lo mejor interesa
hacer una predicción

sobre el valor para otros valores.

Por ejemplo, en la tabla
que teníamos antes,

no había ningún individuo
ni ninguna persona

que midiese 1,60 m.

¿Cuál sería el peso esperado
de esa persona?

Bueno, pues sustituimos 160 cm
en la recta de regresión.

Y esto me dice que podemos esperar
que una persona de 1,60 m

pese 60,53 kg

según este modelo, según esta recta.

El valor estimado,
el valor con el sombrero,

porque el real no lo tenemos,
sería 60,53.

Sería este punto nuevo
que aparecería aquí.

Muy bien, esto sería
el tema de la interpolación,

pero hay que ir con cuidado ahora

a la hora de aplicar
el modelo de regresión.

Este es el riesgo de extrapolación.

Es decir, cuando queremos
encontrar el valor de la Y

a partir de un valor de la X

que se encuentra fuera
del intervalo de valores.

Los valores que hemos tomado
de la X

sirven para establecer el modelo

y puedo aplicar la recta
a valores similares.

En el ejemplo de los pesos
y las alturas,

hemos empezado con alturas
de 1,50 m, aproximadamente.

No tiene sentido preguntarse
por alturas muy diferentes.

No tenemos datos
para recién nacidos de 40 cm.

Hemos cogido personas adultas.

Aquí llegamos hasta 180 cm,
tampoco podemos ir mucho más allá.

No podemos preguntarnos

cuál sería el peso
de una persona de 2 m o por aquí.

Por lo tanto,
hemos de restringir la interpolación

a los rangos de la X
sobre los que tengamos valores.

Si no, podemos obtener
resultados muy diferentes

y poco representativos.

Muy bien.

Una pincelada
sobre relaciones no lineales.

Hemos trabajado
con relaciones lineales,

hemos buscado la recta
que mejor se adapta.

No todos los fenómenos
siguen modelos lineales.

Hay algunos modelos muy conocidos

como, por ejemplo,
algunos fenómenos,

como la población,

las infecciones por un virus
y los precios de algunos productos

que no siguen modelos lineales,

sino que siguen
modelos exponenciales.

Un modelo exponencial
viene a tener una forma como esta,

que va creciendo
cada vez más rápido, si es creciente.

Y en este caso,

el modelo que tenemos
no serviría para detectarlo,

porque esto no es una recta,

pero si recordamos

cómo son los modelos exponenciales,

que son de la forma
 k por a elevado a x ,

fácilmente, tomando logaritmos,
se pueden reducir a modelos lineales.

Se toma un logaritmo,
el logaritmo neperiano de y ,

es logaritmo neperiano
de k por a elevado a x

y aplicando las propiedades
de los logaritmos neperianos,

el producto lo convierto
en una suma

y la x baja multiplicando.

Por lo tanto, me quedaría

que el logaritmo neperiano de y

es el logaritmo neperiano de k
más x

por el logaritmo neperiano de a .

Es decir, es una relación lineal,

pero no entre las variables x e y .

Aquí tengo la x y aquí tengo la y .

Ahora podemos convertir esto

en una relación entre la x
y el logaritmo neperiano de y .

Aquí sí que quedará
un modelo lineal.

Por lo tanto, podríamos aprovechar

lo que hemos estudiado
de la recta de regresión.

Es decir, unos puntos

que más o menos
se van distribuyendo

siguiendo un modelo exponencial,

se pueden transformar
usando logaritmos

para encontrar un modelo lineal

entre la x
y el logaritmo neperiano de y .

Modelos o casos muy conocidos.

Ya lo he dicho,
el tema de la población,

el tema de las infecciones,

todos aquellos que van aumentando,
por ejemplo, un porcentaje.

Muy bien, esto serían
las relaciones no lineales.

Y ahora otro tema
que he avanzado.

Vamos a ver si esta recta
es realmente representativa.

¿Cómo podemos medir
si esta recta de regresión

captura la nube de puntos?

Si realmente los puntos
se adaptan a esta recta.

Y el primer cálculo que haremos
es el coeficiente de determinación.

Este coeficiente
nos indica el grado de ajuste

de la recta
a los valores de la muestra,

y se define como la proporción
de la varianza

explicada por la recta de regresión

respecto a la varianza total
de los datos.

Esto es un poco difícil
de comprender,

pero hemos de tener en cuenta
el tema de los residuos

y el tema de los valores esperados.

La varianza explicada
por la recta de regresión

es la varianza
de los valores estimados:

la varianza de y con sombrero,

la varianza de los valores
que hemos obtenido de la recta.

Y la varianza total de los datos

es la varianza
de los valores observados, de las y .

Es decir, de alguna manera,

esta primera varianza

la calculamos
con los valores estimados,

y esta con los valores observados.

Hay un poco de trabajo
de matemáticas,

y se definen estas tres cantidades:

SQT, la suma
de los cuadrados totales,

que es la diferencia
entre los valores observados

y la media al cuadrado;

SQR, que es la suma
de los cuadrados de los residuos,

aquí en vez de restar la y
menos la media,

es y sombrero menos la media;

y la suma de los cuadrados,

lo que se conoce como SQE,

que es la suma de los residuos
al cuadrado,

e sub i al cuadrado.

Entonces,
haciendo este R al cuadrado,

se define como SQR
dividido por SQT.

Es decir, SQR dividido por SQT.

O bien, también hay que hacer
un poco de manipulación formal,

sería 1 menos SQE
dividido por SQT.

Siempre la idea es esta.

¿Qué proporción

podemos explicar
a partir de la recta de regresión?

Qué proporción de la varianza.

¿Y cuál sería la interpretación?

Bueno, pues si la R al cuadrado es 1,
el ajuste es perfecto.

Toda la varianza la explica
la recta de regresión.

Todos los puntos están
encima de la recta de regresión.

R al cuadrado igual a cero
sería que no hay ninguna relación

entre las variables X e Y .

Y luego todos los valores intermedios.

Cuanto más cerca esté de 1,

más cerca están los puntos
de la recta de regresión.

Por tanto, buscaremos valores
de R al cuadrado próximos a 1.

Esto es lo que hace referencia
al coeficiente de determinación,

R al cuadrado.

Y relacionado con este,

hay otro coeficiente

que se conoce como el coeficiente
de correlación muestral,

que se obtiene dividiendo
la covarianza muestral

por las desviaciones típicas
de la variable.

De las dos variables.

Se puede reformular como la suma

de los productos de las desviaciones
respecto a la media

dividido por esta suma
de las desviaciones al cuadrado.

Esta sería la manera de calcular
el coeficiente de correlación muestral.

Y aquí, este coeficiente tiene signo,
puede ser positivo o negativo.

Evidentemente, la relación es positiva

si valores grandes de X
corresponden a valores grandes de Y ,

y valores pequeños de X
con valores pequeños de Y .

Y la X y la Y
tienen una relación negativa

si valores grandes de X

están emparejados
con valores pequeños de Y ,

y valores pequeños de X
con valores grandes de Y .

Un poco, la relación sería

lo que hemos comentado
de la nube de puntos.

Aquí tendríamos
una relación positiva.

Si es descendiente,
tendremos una relación negativa.

¿Qué casos o cómo interpretamos
el valor numérico?

Si la r es igual a 1 o -1,

la relación es lineal exacta.

En el caso de r igual a 1,
todos están en una recta.

r igual a -1, todos están
en una recta de pendiente negativa.

Se considera
que la relación es débil

si el valor absoluto de r
está entre 0 y 0,5,

y es fuerte si está entre 0,8 y 1,

y moderada, si el valor absoluto
está entre 0,5 y 0,8.

Un poco para ponernos de acuerdo
en el tipo de relaciones:

si es fuerte, débil o moderada.

Sería la relación entre
el coeficiente de correlación muestral

y la bondad del ajuste.

Y finalmente, ¿qué relación hay
entre R al cuadrado y r ?

Bueno, pues se puede,
también, demostrar

que en la regresión lineal simple,

es decir, cuando tenemos
solo dos variables,

se da este fenómeno curioso:

que R al cuadrado
es también r al cuadrado.

El coeficiente de determinación

es el coeficiente
de correlación muestral al cuadrado.

Por lo tanto, a partir de uno
podemos fácilmente calcular el otro.

Bien, vamos a hacer
un pequeño ejemplo.

Consideremos de nuevo
el caso de los pesos y las alturas.

Ya teníamos calculada

la desviación típica de la x ,
la desviación típica de la y

y la covarianza.

Por lo tanto,
con esto ya lo tengo todo.

Divido la covarianza por el producto
de las desviaciones típicas.

Si lo hacemos, da 0,749.

Este es r .

Por lo tanto,
es una relación moderada.

Está llegando al 0,8.

Moderada, casi, casi fuerte.

Y también vemos que al ser positivo,
hay una tendencia creciente.

A valores altos de altura,

le corresponden
valores altos del peso.

¿Cuánto vale
el coeficiente de determinación?

En este caso
hay que hacer el cuadrado.

Calculamos el coeficiente
de correlación al cuadrado

y nos da 0,561.

Por lo tanto, la recta de regresión

explica el 56,1 % de la variabilidad
de las observaciones.

Aquí sí que hay que observar
que si tenemos r ,

para calcular
el coeficiente de determinación,

hacemos el cuadrado.

Y si tenemos R al cuadrado,

pues para calcular r

tenemos que hacer la raíz cuadrada
de R al cuadrado,

pero hay que tener en cuenta el signo,
si es positiva o negativa la r .

Tenemos que mirar
si es creciente o decreciente.

Muy bien, una última pincelada
sobre el tema del ajuste,

y es el tema
del análisis de los residuos.

Una vez hecho el ajuste
del modelo de regresión lineal,

conviene hacer un análisis
de los residuos.

Los residuos son la diferencia
entre los valores observados

y los valores predichos por la recta.

Lo que se suele hacer
es un nuevo gráfico

en que en el eje de abscisas

representaremos
los valores estimados,

y en el eje de ordenadas,
el residuo.

Es decir, para cada valor estimado,

cuál es el residuo
que vamos a obtener.

En general, si el modelo lineal
se ajusta bien,

entonces, la nube de puntos
de estos residuos

no debe mostrar
ningún tipo de estructura.

Este sería un ejemplo
de que los residuos están al azar,

por lo tanto, parece que sí
que sería un buen modelo.

¿Cuándo nos encontraremos
residuos incorrectos

o que nos hagan sospechar?

Si tuviésemos, por ejemplo,

unos residuos
que siguen un modelo cuadrático.

Esto me está diciendo
que la recta no se va a ajustar bien,

porque los residuos
tienen una estructura cuadrática.

Pero en cada caso
hay que representarlo

y, un poco, pensar o ver,

también usando los coeficientes,

hasta qué punto esto
se va a ajustar a la realidad.

Vamos a hacer aquí, también,
un último ejemplo.

Se pueden calcular los residuos.

Aquí hemos hecho...
Para ver un poco cómo se hace,

tenemos los valores de la X ,
los valores de la Y ,

aquí calcularemos los valores
predichos por la recta

utilizando esta fórmula.

Si utilizamos esta fórmula
y sustituimos la X ,

obtendremos estos valores

y también tendremos
los valores de los residuos.

Los valores de los residuos
son restar estas dos filas.

Si lo representamos,
están distribuidos, en todo el rango,

están un poco distribuidos al azar.

Por lo tanto, entre los coeficientes,

entre el análisis de los residuos

y el propio gráfico,

podemos concluir
que el modelo de regresión obtenido

es un buen modelo
para explicar el peso y la altura.

Bien, con esto acabamos
la regresión lineal simple

o lo que sería el cálculo
de la recta de regresión,

sus propiedades
y cómo ver la bondad del ajuste.

Veremos el tema
de regresión lineal simple

estudiando la llamada "inferencia"
dentro del modelo de regresión.

El objetivo es dar un modelo

para todos los individuos
de la población.

Lo denominaremos "modelo
de regresión lineal para la población".

Sencillamente será
lo que ya teníamos,

esta parte sería
la referida a la recta de regresión,

más un error para cada pareja
de valores x sub i e y sub i .

Estos errores son nuevos

y para poder hacer
inferencia estadística,

necesitamos hacer suposiciones,
precisamente, sobre estos errores.

Concretamente, supondremos

que siguen una distribución normal
de media 0,

y una cierta varianza desconocida
sigma al cuadrado,

y también que estos errores
son independientes.

Con estas dos suposiciones,
ya podemos plantearnos el modelo.

Por lo tanto, ahora

tenemos tres parámetros.

Tenemos *beta* sub 0, *beta* sub 1
y *sigma* al cuadrado.

Beta sub 0 y *beta* sub 1
son los que hemos estudiado

con la recta de regresión.

Para estimar *beta* sub 0,

utilizaremos *beta* sub 0 con sombrero,

que era la ordenada en el origen
de la recta de regresión.

Y para estimar *beta* sub 1,

estudiaremos o utilizaremos
la pendiente de la recta de regresión,

que era la covarianza muestral

dividida por la varianza
de *x* al cuadrado.

El problema nuevo ahora

es estimar la varianza de los errores,

y esto se hace a partir
de la varianza de los residuos.

Como no conocemos los errores,

estudiaremos
la varianza de los residuos,

pero dividida por $n-2$.

Es decir, estudiamos la observación

menos su valor predicho por la recta
al cuadrado,

lo sumamos
y dividimos por $n-2$.

s al cuadrado, como está calculada
a partir de los residuos,

se suele denominar
la varianza residual,

y nos permitirá aproximar
una serie de elementos

para hacer la inferencia.

Bien, tenemos ya, pues,
cómo estimar

β_0 , β_1
y σ^2 al cuadrado.

Bien, para hacer
la inferencia estadística,

ahora tenemos que estudiar
la distribución de probabilidad

de β_1 , de la pendiente
de la recta de regresión.

Resulta
que β_1 con sombrero

sigue una distribución normal
con varianza desconocida

y valor esperado β_1 .

Es decir, es un buen estimador
de lo que estamos buscando,

la pendiente de esta recta.

Como esta varianza,
 σ^2 al cuadrado, es desconocida,

definiremos el error estándar
de la pendiente

a partir de la varianza residual.

Dividiremos la varianza residual

dividido por la suma
de las desviaciones

respecto a la media de x al cuadrado.

Este será el error estándar
de la pendiente.

Aquí, en vez de la σ ,
ponemos la varianza residual.

Y dado que β_1 con sombrero
sigue una distribución normal

con varianza desconocida,

ya que no sabemos el valor exacto
de σ^2 al cuadrado,

entonces, esta variable tipificada,

β_1 con sombrero
menos β_1

dividido por el error estándar,

sigue una distribución t de Student
con $n-2$ grados de libertad.

Hemos dividido por $n-2$
en la varianza residual,

y aquí tenemos
 $n-2$ grados de libertad.

Y con esto ya podemos hacer
fácilmente

los intervalos de confianza,
por ejemplo,

e inmediatamente después,

el contraste de hipótesis.

Por ejemplo, el intervalo de confianza,
con este nivel,

para la pendiente

de la recta de regresión poblacional,

viene determinado
por la fórmula de siempre:

el estimador,
beta sub 1 con sombrero,

menos el valor crítico

de una *t* de Student
con *n*-2 grados de libertad

por el error estándar de la pendiente.

Aquí restamos y aquí sumamos.

La típica forma de encontrar
el intervalo de confianza.

Esta sería la manera de calcularlo.

Y si queremos hacer inferencia,

un contraste de hipótesis,

aquí tenemos que explicar
o explicitar,

primero, las hipótesis.

Lo que haremos será fijarnos
en si la pendiente es 0 o no.

¿Por qué?

Si la pendiente es 0,
tendríamos una recta horizontal,

es decir, la variable X no explica nada respecto a la Y .

Tenemos una recta horizontal.

Por lo tanto, la hipótesis nula será β_1 igual a 0.

Variable X no explicativa.

Y la alternativa β_1 diferente de 0,

caso en el que la variable X se considera explicativa.

Fijaremos el nivel de significación

y calcularemos el estadístico de contraste.

Será β_1 con sombrero, la pendiente de la recta de regresión,

dividido por el error estándar,

que es una observación, otra vez,

de una distribución t de Student con $n-2$ grados de libertad

bajo la hipótesis nula.

¿Cómo decidiremos?
Pues como siempre.

A partir del p -valor

calcularemos la probabilidad
de que el valor absoluto

de esta distribución t

sea más grande que el valor absoluto
del estadístico de contraste,

y si p es menor o igual que α ,

rechazaremos la hipótesis nula

y, por lo tanto,
la variable será explicativa.

Si queremos usar los valores críticos,

miraremos si el valor absoluto

del estadístico de contraste
es más grande que el valor crítico

y rechazaremos H_0 .
Rechazaremos la hipótesis nula.

Y recordemos que el valor crítico
es aquel valor

del que la probabilidad
de estar más alejado

será $\alpha/2$ medios.

Como siempre, hemos hecho ya

el cálculo
de todos los valores críticos.

Bien, con esto

ya tenemos la fórmula,

sobre todo el estadístico
de contraste y la distribución

para poder hacer un ejemplo.

Continuaremos con el ejemplo
de las alturas y los pesos.

Queremos contrastar
la hipótesis nula

de que la variable X no es explicativa,
o sí, de la variable Y .

Es decir, queremos ver si la altura
es explicativa del peso o no.

La hipótesis nula será que no lo es

y la hipótesis alternativa,
que sí que lo es.

Nivel de significación: 0,05.

¿Y el estadístico de contraste?

Aquí tenemos los cálculos,
están en las notas de estudio,

pero vamos a repasar un poquito
cómo se harían.

$Beta$ sub 1 ya lo teníamos calculado
en el estudio anterior,

y ahora tendríamos que calcular
la varianza residual

a partir de este cuadro
que ya teníamos antes.

La varianza residual sería

la suma de los cuadrados
de los errores,

vamos a ir sumando estos errores,

para luego hacer el cuadrado
y dividir por $n-2$.

Esto dará 44,536.

Y con esto podemos dividir
la varianza residual

por la suma de las desviaciones
de la x al cuadrado.

Las teníamos calculadas antes,
también, y da 0,093.

Por lo tanto,

tenemos que el error estándar
será 0,306.

Aquí sería... La raíz cuadrada
será este valor: 306.

Entonces, calculamos
este estadístico de contraste

y da 3,202.

Esto serían los cálculos
que tenemos que hacer

para encontrar el valor
del estadístico de contraste.

Muy bien, una vez calculado
el estadístico de contraste,

vamos a decidir, a partir del p -valor,

la probabilidad
de que el valor absoluto

de una distribución t de Student
de 8 grados de libertad

sea más grande que 3,202.

Esto se puede hacer con r
o con una tabla, y me da 0,0126,

que es inferior a 0,05.

Por lo tanto,
rechazamos la hipótesis nula.

Es decir, la variable es explicativa.

A partir del valor crítico...

Podemos calcular este valor crítico,
que es 2,30.

Y ahora tenemos que el valor crítico

es más pequeño
que el estadístico de contraste.

Por lo tanto,
el estadístico de contraste

está más alejado que el valor crítico.

Por eso llegamos
a la misma conclusión.

Podemos concluir
que la variable "altura" es explicativa.

Perdón, X.

Rechazamos la hipótesis nula

y podemos concluir
que la variable "altura"

es explicativa
del peso de las personas.

La variable es explicativa
en los dos casos.

Finalmente, podríamos calcular
un intervalo de confianza

con todos los valores
que ya tenemos calculados.

El intervalo de confianza
sería 0,274,

1,684.

Como no contiene el 0,

vemos que la pendiente
es diferente a 0

y, por lo tanto, la variable X

es explicativa,

tal como también ha resuelto
nuestro contraste de hipótesis.

Bien, y con esto acabamos el tema
de regresión lineal simple,

habiendo estudiado, también,
la inferencia en la regresión.