



PEC4: Introducción al aprendizaje computacional

Presentación

Cuarta PEC del curso de Inteligencia Artificial

Competencias

En esta PEC se trabajarán las siguientes competencias:

Competencias de grado:

- Capacidad de analizar un problema con el nivel de abstracción adecuado a cada situación y aplicar las habilidades y conocimientos adquiridos para abordarlo y solucionarlo.

Competencias específicas:

- Conocer los diferentes aspectos del aprendizaje computacional (aprendizaje supervisado, no supervisado y por refuerzo).
- Conocer los fundamentos teóricos de los métodos más representativos.
- Conocer el tratamiento de los conjuntos de datos para la correcta validación de los sistemas de aprendizaje.

Objetivos

Esta PEC pretende evaluar diferentes aspectos de aprendizaje supervisado y no supervisado.

Descripción de la PEC a realizar

Pregunta 1 (25p):

Una clínica veterinaria quiere clasificar automáticamente muestras de tejido animal según tres características medidas en laboratorio. Las características son: nivel de proteína (A1), nivel de glucosa (A2) y temperatura de muestra en grados (A3). Las clases posibles son: Tipo X, Tipo Y y Tipo Z.

Conjunto de entrenamiento:



ID	A1	A2	A3	Clase
1	2	3	1	X
2	4	1	2	X
3	6	5	3	Y
4	5	4	5	Y
5	1	6	4	Z
6	3	7	6	Z

Muestra de test: $\mathbf{x} = (A1=3.0, A2=4.0, A3=2.0)$

- a) Calcula la distancia euclídea entre la muestra de test $\mathbf{x}$ y cadauno de los 6 ejemplos del conjunto de entrenamiento. Muestra el desarrollo completo de cada cálculo. [10 p]
- b) Indica qué clase asignarías a la muestra $\mathbf{x}$ usando el clasificador 1NN. Justifica tu respuesta con los resultados del apartado anterior. [5 p]
- c) Indica qué clase asignarías a la muestra $\mathbf{x}$ usando el clasificador 3NN. En caso de empate en la votación, razona cómo lo resolverías. [5 p]
- d) El kNN tiene un coste computacional alto en la fase de clasificación cuando el conjunto de entrenamiento es muy grande. Explica por que ocurre esto y propón una estrategia conceptual para reducir ese coste sin cambiar el algoritmo por otro completamente diferente. [5 ps]

[Soluciones]

a)

$$\text{Fórmula: } d(\mathbf{x}, \mathbf{x}_i) = \sqrt{(3-A1)^2 + (4-A2)^2 + (2-A3)^2}$$

$$d(\mathbf{x}, \text{ID1}) = \sqrt{(3-2)^2 + (4-3)^2 + (2-1)^2} = \sqrt{1 + 1 + 1} = \sqrt{3} = 1.7321$$

$$d(\mathbf{x}, \text{ID2}) = \sqrt{(3-4)^2 + (4-1)^2 + (2-2)^2} = \sqrt{1 + 9 + 0} = \sqrt{10} = 3.1623$$

$$d(\mathbf{x}, \text{ID3}) = \sqrt{(3-6)^2 + (4-5)^2 + (2-3)^2} = \sqrt{9 + 1 + 1} = \sqrt{11} = 3.3166$$



$$d(x, ID4) = \sqrt{[(3-5)^2 + (4-4)^2 + (2-5)^2]} = \sqrt{[4 + 0 + 9]} = \sqrt{13} = 3.6056$$

$$d(x, ID5) = \sqrt{[(3-1)^2 + (4-6)^2 + (2-4)^2]} = \sqrt{[4 + 4 + 4]} = \sqrt{12} = 3.4641$$

$$d(x, ID6) = \sqrt{[(3-3)^2 + (4-7)^2 + (2-6)^2]} = \sqrt{[0 + 9 + 16]} = \sqrt{25} = 5.0000$$

b)

El vecino más cercano es ID1 ($d = 1.7321$), que pertenece a la clase Tipo X. → Predicción: Tipo X

c)

Los 3 vecinos más cercanos son: ID1 (Tipo X), ID2 (Tipo X), ID3 (Tipo Y).

Votación: Tipo X obtiene 2 votos, Tipo Y obtiene 1 voto. → Predicción: Tipo X (no hay empate).

d)

En KNN, el entrenamiento es nulo (se almacenan los datos), pero clasificar cada nueva muestra requiere calcular la distancia a todos los ejemplos del conjunto de entrenamiento. Si hay N ejemplos y M atributos, el coste es $O(N \cdot M)$ por muestra. Con N grande esto escala muy mal.

Potenciales estrategias (depende del estudiante):

- Reducción del conjunto de entrenamiento, seleccionando solo los ejemplos más representativos como prototipos.
- Usar estructuras de indexación espacial que agrupan los puntos de entrenamiento en un árbol y evitan calcular distancias a todos los puntos, reduciendo el coste medio



Pregunta 2 (25p):

Un sistema automatizado debe clasificar solicitudes de crédito bancario como Aprobadas (A) o Rechazadas (R) en función de tres atributos categóricos del solicitante.

ID	Empleo	Historial	Ingresos	Class
1	Fijo	Bueno	Alto	A
2	Temporal	Bueno	Medio	A
3	Fijo	Malo	Alto	R
4	Temporal	Malo	Bajo	R
5	Fijo	Bueno	Medio	A
6	Fijo	Malo	Medio	R
7	Temporal	Bueno	Alto	A
8	Temporal	Malo	Alto	R

a) Calcula la bondad de la partición para cada uno de los tres atributos (Empleo, Historial, Ingresos) usando el criterio de clase mayoritaria descrito en el módulo. Muestra todos los conjuntos generados y el número de ejemplos bien clasificados. [12 p]

b) Selecciona el atributo raíz del árbol e indica si alguno de los nodos resultantes ya es terminal. Para los nodos internos, aplica una segunda iteración del algoritmo (sin entrar en una tercera). [8 p]

c) Clasifica la siguiente muestra de test usando el árbol construido y justifica el recorrido rama a rama:

Muestra test: Empleo=Fijo, Historial=Malo, Ingresos=Alto

d) ¿Cuál es la principal ventaja del árbol de decisión respecto al kNN en un contexto bancario real? Razona tu respuesta[5 p]



[Solucion]

a)

Bondades

Empleo:

Fijo (IDs 1,3,5,6): clases = A, R, A, R → mayoría = empate → ambas valen; se toman 2 correctos.

Temporal (IDs 2,4,7,8): clases = A, R, A, R → mayoría = empate → 2 correctos.

bondad(Empleo) = (2 + 2) / 8 = 0.500

Historial:

Bueno (IDs 1,2,5,7): clases = A, A, A, A → mayoría = A → 4 correctos.

Malo (IDs 3,4,6,8): clases = R, R, R, R → mayoría = R → 4 correctos.

bondad(Historial) = (4 + 4) / 8 = 1.000

Ingresos:

Alto (IDs 1,3,7,8): clases = A, R, A, R → mayoría = empate → 2 correctos.

Medio (IDs 2,5,6): clases = A, A, R → mayoría = A → 2 correctos.

Bajo (IDs 4): clases = R → mayoría = R → 1 correcto.

bondad(Ingresos) = (2 + 2 + 1) / 8 = 0.625

b)

El atributo raíz es Historial (bondad = 1.0, separa perfectamente las clases).

Nodo Historial=Bueno → todos los ejemplos son clase A → NODO TERMINAL: Aprobado.

Nodo Historial=Malo → todos los ejemplos son clase R → NODO TERMINAL: Rechazado.

El árbol tiene profundidad 1. No se necesita segunda iteración porque ambos nodos son terminales.

c)

Test: Empleo=Fijo, Historial=Malo, Ingresos=Alto.

Paso 1: Raíz → atributo Historial. Valor=Malo → ir al nodo derecho.



Paso 2: Nodo terminal → Clase = Rechazada (R). Predicción: R.

d)

La principal ventaja del árbol frente al kNN en banca es la Interpretabilidad. El árbol genera reglas explícitas (ej: Si Historial=Malo -> Rechazar) que los auditores y reguladores pueden revisar y justificar. El kNN es una caja negra: solo compara distancias y no explica por qué se acepta o rechaza. En sectores regulados (banca, seguros, gobierno,...) se suele exigir por ley que las decisiones sean explicables.

Pregunta 3 (25p)

Se dispone de un perceptrón con 2 neuronas de entrada, una capa oculta de 2 neuronas y 1 neurona de salida. La función de activación de las neuronas ocultas es ReLU. La neurona de salida aplica una función lineal. Los pesos y sesgos son fijos y se dan a continuación:

Arquitectura y parámetros:

Capa de entrada → capa oculta (pesos w , sesgo b):

- Neurona oculta H1: $w_{11} = 0.5$, $w_{21} = 0.2$, $b_1 = 0.1$
- Neurona oculta H2: $w_{12} = -0.3$, $w_{22} = 0.8$, $b_2 = -0.2$

Capa oculta → neurona de salida (pesos v , sesgo b_{out}):

- $v_1 = 0.7$, $v_2 = -0.4$, $b_{out} = 0.3$

Entrada: $x = (x_1 = 1.5, x_2 = 2.0)$

Salida esperada (etiqueta): $y^* = 1.2$

a) Calcula la entrada neta y la salida de cada neurona oculta (H1 y H2). Muestra el cálculo de la suma ponderada antes y después de aplicar ReLU. (8 p)

b) Calcula la salida final de la red ($\hat{y}$) a partir de las salidas de H1 y H2. (5 p)

c) Calcula el error cuadrático C entre la salida obtenida $\hat{y}$ y la etiqueta y^* . (4 p)

d) Supón ahora que el peso w_{12} cambia de -0.3 a $+0.6$ (manteniendo todo lo demás igual). Sin recalcular todos los pasos desde cero, razona cualitativamente: ¿aumentará o



disminuirá la activación de H2? ¿Qué efecto tendrá esto en la salida final $\hat{y}$ y en el error C? (8 p)

[Solucion]

a)

Neurona H1:

$$z_1 = w_{11} \cdot x_1 + w_{21} \cdot x_2 + b_1 = 0.5 \cdot 1.5 + 0.2 \cdot 2.0 + 0.1 = 0.75 + 0.40 + 0.10 = 1.25$$

$$\text{ReLU}(1.25) = 1.25 \text{ (positivo)} \rightarrow h_1 = 1.25$$

Neurona H2:

$$z_2 = w_{12} \cdot x_1 + w_{22} \cdot x_2 + b_2 = (-0.3) \cdot 1.5 + 0.8 \cdot 2.0 + (-0.2) = -0.45 + 1.60 - 0.20 = 0.95$$

$$\text{ReLU}(0.95) = 0.95 \text{ (positivo)} \rightarrow h_2 = 0.95$$

b)

$$\hat{y} = v_1 \cdot h_1 + v_2 \cdot h_2 + b_{\text{out}} = 0.7 \cdot 1.25 + (-0.4) \cdot 0.95 + 0.3$$

$$\hat{y} = 0.875 - 0.380 + 0.300 = 0.795$$

c)

$$C = (y^* - \hat{y})^2 = (1.2 - 0.795)^2 = (0.405)^2 = 0.1640$$

d)

Cambio: w_{12} pasa de -0.3 a $+0.6$. La entrada neta de H2 es $z_2 = w_{12} \cdot x_1 + w_{22} \cdot x_2 + b_2$.

Con $x_1=1.5$ (positivo), aumentar w_{12} aumenta z_2 : nuevo $z_2 = 0.6 \cdot 1.5 + 0.8 \cdot 2.0 - 0.2 = 0.90 + 1.60 - 0.20 = 2.30$.

Como z_2 sigue siendo positivo, $\text{Relu}(2.30) = 2.30 \rightarrow h_2 = 2.30$ (mucho mayor que antes: 0.95).

Efecto en la salida: el peso $v_2=-0.4$ es negativo, así que un h_2 mayor reduce la salida $\hat{y}$.

Nuevo $\hat{y}$ estimado $\approx 0.7 \cdot 1.25 + (-0.4) \cdot 2.30 + 0.3 = 0.875 - 0.920 + 0.300 = 0.255$.

El error aumentaría: $C = (1.2 - 0.255)^2 = (0.945)^2 \approx 0.893$. El cambio empeora el modelo para esta muestra



Pregunta 4 (25p)

Un sistema de aprendizaje supervisado ha sido entrenado para detectar si una planta tiene una enfermedad (Positivo = enferm, Negativo = sana). Se ha evaluado sobre un conjunto de test de 200 muestras y se han obtenido los resultados siguientes expresados en la matriz de confusión.

	Positivo	Negativo
Positivo	45	15
Negativo	20	120

a) Calcula las siguientes métricas mostrando la fórmula, la sustitución numérica y el resultado final: [12 p]

- Exactitud (Accuracy)
- Precisión (Precision)
- Sensibilidad (Recall)
- Medida F1

b) En el contexto de la detección de enfermedades en plantas, ¿cuál de las cuatro métricas anteriores consideras que debería ser la métrica prioritaria para evaluar este sistema?

Argumenta tu elección teniendo en cuenta las consecuencias de los falsos negativos (FN) y los falsos positivos (FP) en este dominio. [7 p]

c) Un investigador propone usar validación cruzada con $k=8$ en lugar de validación simple (holdout) sobre un conjunto de 400 muestras. Explica: [6 p]

- ¿Cuántas muestras se usarían como test en cada iteración?
- ¿Cuántas veces se entrenaría el modelo en total?
- ¿Por qué la validación cruzada da estimaciones más fiables que la validación simple?



[Solucion]

a)

$$\text{Exactitud} = (VP + VN) / \text{Total} = (45 + 120) / 200 = 165 / 200 = 0.8250$$

$$\text{Precisión} = VP / (VP + FP) = 45 / (45 + 15) = 45 / 60 = 0.7500$$

$$\text{Sensibilidad (Recall)} = VP / (VP + FN) = 45 / (45 + 20) = 45 / 65 = 0.6923$$

$$F1 = 2 \cdot (\text{Precisión} \cdot \text{Recall}) / (\text{Precisión} + \text{Recall}) = 2 \cdot (0.75 \cdot 0.6923) / (0.75 + 0.6923)$$

$$F1 = 2 \cdot 0.5192 / 1.4423 = 1.0385 / 1.4423 = 0.7200$$

b)

La métrica prioritaria debería ser Recall.

Un falso negativo significa que una planta enferma es clasificada como sana. En agricultura, esto implica no tratar la enfermedad, con el riesgo de que se propague a otras plantas, generando pérdidas económicas graves. Un falso positivo implica tratar innecesariamente una planta sana, lo que tiene un coste pero es mucho menos grave.

Por tanto, se debe maximizar la tasa de detección de enfermedades reales (Recall), aunque ello implique un aumento de los FP. La F1 es también un buen candidato si se quiere equilibrio, pero si los costes son asimétricos, Recall es preferible.

c)

Muestras por iteración como test: $400 / 8 = 50$ muestras. Las otras 350 son de entrenamiento.

Número total de entrenamientos: $k = 8$ (uno por cada partición).



Con la validación simple (holdout), el resultado depende de una partición aleatoria, que puede ser favorable o desfavorable por azar. Con k-fold, se obtienen **k** estimaciones del rendimiento y se calcula su media y desviación estándar, lo que da una medida más estable y menos sensible a la partición particular elegida.

Recursos

Para hacer esta PEC el material imprescindible es el módulo 5.

Criterios de valoración

Las puntuaciones se muestran en cada pregunta del enunciado.

Formato y fecha de entrega

Para dudas y aclaraciones sobre el enunciado, dirigiros al consultor responsable del aula.

Hay que entregar la solución en un archivo PDF usando una de las plantillas entregadas conjuntamente con este enunciado. Adjuntar el fichero a un mensaje en el apartado Entrega y Registro de EC (REC).

El nombre del archivo debe ser *Apellidos_Nombre_IA_PEC4* con la extensión .pdf (PDF).

La fecha límite de entrega es el: **02/01/2025** (a las 24 horas).

Razonad la respuesta en todos los ejercicios. Las respuestas sin justificación no recibirán puntuación.

Nota: Propiedad intelectual

A menudo es inevitable, al producir una obra multimedia, hacer uso de recursos creados por terceras personas. Es por tanto comprensible hacerlo en el marco de una práctica de los estudios de Informática, siempre que se documente claramente y no suponga plagio en la práctica.

Por lo tanto, al presentar una práctica que haga uso de recursos ajenos, se presentará junto con ella un documento en el que se detallen todos ellos, especificando el nombre de cada recurso, su autor, el lugar donde se obtuvo y el su estatus legal: si la obra está protegida por copyright o se acoge a alguna otra licencia de uso (Creative Commons, licencia GNU, GPL ...).

El estudiante deberá asegurarse de que la licencia que sea no impide específicamente su uso en el marco de la práctica. En caso de no encontrar la información correspondiente deberá asumir que la obra está protegida por copyright.

Deberán, además, adjuntar los archivos originales cuando las obras utilizadas sean digitales, y su código fuente.